

Sistema de Predicción Adaptativa de Deserción Estudiantil en Instituciones de Educación Superior Mediante Modelos Estadísticos y de Aprendizaje Automático

Juan Pablo Nieto Cortés Juan Sebastián Buitrago Piñeros

Ingeniería de Sistemas

Escuela Colombiana de Ingeniería Julio Garavito
Bogotá, Colombia

Mayo 2026

Resumen

La deserción estudiantil en la educación superior es uno de los fenómenos más costosos para las instituciones latinoamericanas. Este artículo presenta el diseño, implementación y validación de un sistema de predicción adaptativa que integra cinco modelos de aprendizaje automático —Regresión Logística, Árbol de Decisión, Bosque Aleatorio, SVM y Red Neuronal Multicapa— con análisis de supervivencia (Kaplan-Meier y Cox PH). El sistema fue validado sobre 4424 registros de estudiantes universitarios, empleando una partición estratificada 80/20 y SMOTE para corregir el desbalance de clases. El Bosque Aleatorio obtuvo una exactitud del 91,2% y un AUC-ROC de 0,961. Un mecanismo de umbral adaptativo basado en el índice de Youden permite ajustar la sensibilidad según la capacidad de cada institución. El sistema se despliega en AWS con una interfaz React que expone paneles de análisis, ranking de estudiantes en riesgo y curvas de supervivencia en tiempo real.

Palabras clave: deserción estudiantil, aprendizaje automático, análisis de supervivencia, umbral adaptativo, índice de Youden, Kaplan-Meier, AWS, microservicios, educación superior, SMOTE.

1. Introducción

El abandono estudiantil es uno de los desafíos más costosos para los sistemas de educación superior en América Latina. En Colombia, la tasa de deserción acumulada para el período 2002–2007 alcanzó el 47%, cercana al promedio latinoamericano (50%) [1], con impacto directo en la productividad del país y la eficiencia de la inversión pública en educación.

La mayoría de las instituciones reacciona de forma tardía: actúan cuando el estudiante ya abandonó, limitando la posibilidad de intervención oportuna [1,3]. El avance del *Machine*

Learning (ML) ha abierto alternativas concretas para anticipar el abandono —con precisiones entre el 78 % y el 96 % [3–5]—, pero estos sistemas rara vez se traducen en herramientas institucionales reutilizables.

Este trabajo presenta un **sistema de predicción adaptativa** que: (i) integra múltiples modelos de ML y análisis de supervivencia en una plataforma unificada; (ii) aplica un umbral de clasificación adaptativo basado en el índice de Youden; (iii) se despliega en la nube (AWS) como aplicación web de uso inmediato; y (iv) ofrece una interfaz visual que convierte las predicciones en información accionable para directivos y consejeros académicos.

2. Planteamiento del Problema

Las instituciones educativas carecen de herramientas que identifiquen, de forma automática y oportuna, a los estudiantes con mayor riesgo de abandono. Cuando el equipo directivo detecta la señal de alerta —generalmente al cierre del período—, el margen de acción es mínimo.

2.1. Pregunta de Investigación

¿Es posible predecir el riesgo de abandono estudiantil usando variables académicas del primer semestre y factores socioeconómicos, con un nivel de precisión que justifique intervenciones tempranas y focalizadas?

2.2. Problemas Específicos

- P1.** Las instituciones no disponen de sistemas de alerta temprana que integren variables académicas, demográficas y socioeconómicas.
- P2.** Los modelos predictivos no ofrecen mecanismos de calibración del umbral de riesgo según la capacidad de intervención institucional.
- P3.** La mayoría de soluciones existentes carece de una interfaz que traduzca los resultados en decisiones operativas concretas.
- P4.** No existe consenso sobre qué modelo de ML ofrece el mejor equilibrio entre sensibilidad y especificidad en datos de deserción desbalanceados.

3. Objetivos

3.1. Objetivo General

Diseñar, implementar y validar un sistema de predicción adaptativa de deserción estudiantil que integre modelos estadísticos y de aprendizaje automático en una arquitectura desplegable en la nube, ofreciendo una interfaz institucional para la toma de decisiones preventivas.

3.2. Objetivos Específicos

- Analizar las variables académicas y socioeconómicas más relevantes para la predicción del abandono a partir del dataset y la literatura especializada.
- Implementar y comparar cinco modelos de ML sobre el conjunto de datos seleccionado.
- Implementar modelos de análisis de supervivencia (Kaplan-Meier y Cox PH) para identificar los semestres de mayor riesgo dentro de una cohorte.
- Diseñar un mecanismo de umbral adaptativo basado en el índice de Youden.
- Desplegar el sistema en AWS con una interfaz React y una API REST documentada.
- Evaluar los modelos con métricas robustas: exactitud, precisión, sensibilidad, F1-Score y AUC-ROC.

4. Hipótesis

H1 Es posible predecir el abandono estudiantil con una exactitud superior al 80 % usando variables académicas del primer semestre combinadas con factores socioeconómicos.

H2 El índice de Youden para calibrar el umbral de clasificación mejora el F1-Score en al menos cinco puntos porcentuales respecto al umbral fijo $\tau = 0,5$.

5. Marco Teórico

5.1. Modelos Conceptuales de la Deserción

El modelo de integración estudiantil de Tinto (1975) sostiene que la decisión de abandonar los estudios está relacionada con el grado de integración académica (rendimiento, interacción con docentes) y social (relaciones con pares, actividades extracurriculares) del estudiante [1]. El Ministerio de Educación Nacional de Colombia define al desertor como el estudiante que **no presenta actividad académica durante dos semestres consecutivos** [1]. Esta definición constituye la variable objetivo del sistema propuesto.

5.2. Estimador de Kaplan-Meier

El análisis de supervivencia no solo predice *si* un estudiante abandona, sino *cuándo* es probable que lo haga [2]. El estimador de Kaplan-Meier calcula la probabilidad de permanecer matriculado más allá del semestre t :

$$\hat{S}(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right) \quad (1)$$

donde d_i es el número de deserciones en el instante t_i y n_i el número de estudiantes que aún permanecen justo antes de t_i . El producto acumulado captura el riesgo compuesto de

cada semestre. Los estudiantes que no han completado su trayectoria (activos o graduados) se tratan como *observaciones censuradas*: se descuentan del denominador a partir del momento en que salen del seguimiento, sin distorsionar la curva.

5.3. Modelo de Riesgo Proporcional de Cox

El modelo de Cox cuantifica cómo influyen las características de un estudiante en su riesgo de abandonar en cada semestre [11]:

$$h(t \mid \mathbf{x}) = h_0(t) \cdot e^{\mathbf{w}^T \mathbf{x}} \quad (2)$$

¿Qué significa cada término? $h(t \mid \mathbf{x})$ es la probabilidad instantánea de deserción en el semestre t para un estudiante con características $\mathbf{x}$. $h_0(t)$ es el riesgo basal: el riesgo promedio de la cohorte en cada semestre, independiente de cualquier variable individual. $e^{\mathbf{w}^T \mathbf{x}}$ es el factor que ajusta ese riesgo según las características del estudiante; si el resultado es mayor que 1, el riesgo aumenta; si es menor que 1, disminuye.

Hazard Ratio (HR). El coeficiente $\text{HR}_j = e^{w_j}$ indica el efecto multiplicativo de cada variable sobre el riesgo. La Tabla 1 resume la interpretación:

Cuadro 1: Interpretación del Hazard Ratio en el contexto de deserción

HR	Interpretación	Ejemplo
> 1	Aumenta el riesgo de deserción	Deudor de matrícula
< 1	Factor protector	Becario, materias aprobadas
$= 1$	Sin efecto sobre el riesgo	—

Resultados para el dataset. Los hallazgos más relevantes son: las unidades curriculares aprobadas en el primer semestre actúan como **factor protector** ($\text{HR} < 1$, $p < 0,001$) —cada materia adicional aprobada reduce el riesgo en aprox. un 15 %—; la condición de **deudor de matrícula** es el mayor factor de riesgo ($\text{HR} > 1,5$, $p < 0,01$); y la tasa de desempleo eleva el riesgo en estudiantes que trabajan simultáneamente.

5.4. Umbral Adaptativo y el Índice de Youden

Para clasificar a un estudiante como “en riesgo” se usa un umbral de probabilidad τ : si la probabilidad predicha de deserción supera τ , se emite la alerta. El umbral estándar $\tau = 0,5$ asume costos simétricos entre errores, lo que no es adecuado aquí: *no detectar a un desertor real* es mucho más costoso que *alertar sobre alguien que no desertará*. El sistema determina el umbral óptimo mediante el **índice de Youden** J :

$$J(\tau) = \text{Sensibilidad}(\tau) + \text{Especificidad}(\tau) - 1 \quad (3)$$

La Sensibilidad mide la proporción de desertores reales correctamente detectados; la Especificidad, la proporción de no-desertores correctamente descartados. J oscila entre 0 (clasificación aleatoria) y 1 (clasificación perfecta). Maximizar J encuentra el punto de la curva ROC más alejado de la diagonal aleatoria, es decir, el mejor equilibrio entre ambas métricas.

Comparativa práctica. La Tabla 2 muestra el impacto concreto sobre el Bosque Aleatorio entrenado en el dataset:

Cuadro 2: Umbral convencional vs. umbral óptimo (Bosque Aleatorio)				
τ	Alertados	Sensibilidad	Especificidad	J Youden
0,50 (convencional)	1 401	82,1 %	81,0 %	0,631
0,46 (óptimo)	1 529	86,4 %	77,3 %	0,637

El umbral óptimo detecta 47 desertores adicionales al costo de 128 alertas extra no críticas. Dado que el costo de una intervención preventiva es mucho menor que el de una deserción consolidada, este intercambio es institucionalmente favorable.

Semáforo institucional. La interfaz web permite ajustar τ en tiempo real mediante un control deslizante. El semáforo del Dashboard clasifica automáticamente el nivel de riesgo global: riesgo Bajo ($< 20\%$ de estudiantes sobre τ), Medio ($20\text{--}40\%$) o Alto ($> 40\%$).

5.5. Arquitectura de Software y Principios Distribuidos

El sistema implementa una arquitectura orientada a servicios con separación clara entre la capa de presentación (React), la capa de lógica analítica (FastAPI) y la capa de datos (AWS RDS).

6. Estado del Arte

6.1. Variables Predictivas: Consensos en la Literatura

La literatura identifica cuatro grupos de factores como los más determinantes:

- **Académicos:** El rendimiento en los primeros semestres —materias aprobadas y promedio de calificaciones— es el predictor más potente [3].
- **Socioeconómicos:** El SPADIES [1] identifica la deuda de matrícula y la condición de becario como determinantes clave. Los estudiantes con deudas activas pueden tener hasta tres veces mayor probabilidad de deserción.
- **Macroeconómicos:** La tasa de desempleo y el PIB modulan el riesgo, especialmente en estudiantes que trabajan [1].

6.2. Técnicas de Machine Learning en Predicción de Deserción

Los Bosques Aleatorios reportan AUC-ROC superiores a 0,90 [3], y variantes de gradient boosting superan el 96 % [4]. Bríñez-de-León et al. [4] proponen transformar datos tabulares en imágenes sintéticas para aplicar CNNs, obteniendo 87 % de exactitud. El desbalance de clases (30–40 % desertores vs. 60–70 % no-desertores) exige técnicas como SMOTE para evitar sesgo del clasificador [3].




Figura 1: Tasa de deserción por departamento en Colombia, basada en datos del SPADIES [1]. Las disparidades regionales refuerzan la necesidad de sistemas adaptativos.




Figura 2: Comparativa de deserción entre sector oficial y privado en Colombia.

7. Descripción del Dataset

El sistema fue validado con el dataset *Predict students' dropout and academic success* [6], del Instituto Politécnico de Portalegre (Portugal).

7.1. Características

- **Registros:** 4 424 estudiantes universitarios
- **Variables:** 35 atributos de entrada (Tabla 3)
- **Variable objetivo:** *Dropout* (32,1 %), *Graduate* (49,9 %), *Enrolled* (18,0 %)

Cuadro 3: Categorías de variables de entrada del dataset

Categoría	Cant.	Ejemplos
Demográficas	5	Edad al ingreso, género, estado civil, nacionalidad
Socioeconómicas	8	Becario, deudor, matrícula al día, cualificación padres
Académicas Sem. 1	6	UC matriculadas, aprobadas, calificación promedio
Académicas Sem. 2	6	UC matriculadas, aprobadas, calificación promedio
Institucionales	6	Modalidad (diurno/nocturno), curso, vía de admisión
Macroeconómicas	3	Tasa de desempleo, inflación, PIB
Calificación previa	1	Nota antes del ingreso universitario

7.2. Tratamiento del Desbalance de Clases

Para el entrenamiento de los clasificadores se excluyen los registros *Enrolled* (resultado aún desconocido), resultando en aprox. 26 % desertores frente a 74 % graduados. Este desbalance se corrige mediante SMOTE, técnica descrita en la Sección 9.1.

8. Arquitectura del Sistema

8.1. Arquitectura General Propuesta (Diseño Conceptual)

Durante la etapa de diseño del proyecto se planteó una arquitectura de referencia de alta disponibilidad y escalabilidad horizontal para producción empresarial. Es importante aclarar que esta arquitectura corresponde a un **diseño conceptual inicial** y **no fue la solución finalmente implementada**; su propósito es ilustrar el modelo arquitectónico objetivo al que podría evolucionar el sistema en un despliegue institucional de mayor escala.

La Figura 3 presenta el diagrama completo de esta arquitectura de referencia sobre AWS en la región `us-east-1`.




Figura 3: Arquitectura general propuesta durante la etapa de diseño. Corresponde a un modelo conceptual de alta disponibilidad orientado a producción empresarial, que no fue implementado en el desarrollo final del proyecto.

Los componentes centrales de esta arquitectura propuesta son los siguientes:

- **Route 53 (DNS):** Servicio de resolución de nombres que dirige el tráfico entrante hacia CloudFront, actuando como punto de entrada único al sistema.
- **CloudFront (CDN):** Distribuye el contenido estático del frontend (React) alojado en **Amazon S3**, reduciendo la latencia para usuarios en distintas ubicaciones geográficas.
- **Application Load Balancer (ALB):** Distribuye el tráfico dinámico (peticiones a la API) entre las instancias EC2 activas en las distintas zonas de disponibilidad, garantizando tolerancia a fallos.

- **VPC con tres zonas de disponibilidad (AZ1, AZ2, AZ3):** Cada zona contiene una subred pública con un *Auto Scaling Group* de dos instancias EC2 y un *NAT Gateway* para tráfico saliente. La escalabilidad horizontal se gestiona automáticamente según la carga del sistema.
- **Internet Gateway:** Permite la comunicación entre la VPC y el exterior, habilitando el acceso de los usuarios a los recursos públicos del sistema.
- **RDS MySQL Multi-AZ con réplicas:** La capa de datos se distribuye en subredes privadas con tres nodos: una base de datos primaria en AZ1, una réplica de espera (*Standby DB*) en AZ2 sincronizada de forma síncrona, y una réplica de lectura (*Read Replica*) en AZ3 replicada de forma asíncrona. Esta configuración garantiza continuidad del servicio ante fallos de zona y permite distribuir la carga de lecturas.

Esta arquitectura propuesta prioriza la alta disponibilidad, la recuperación ante desastres y la escalabilidad automática. No obstante, su implementación requiere una inversión en infraestructura y configuración significativamente mayor a la alcanzada en el prototipo desarrollado, razón por la cual se optó por la solución descrita en la siguiente subsección.

8.2. Arquitectura Implementada

A diferencia del diseño conceptual presentado anteriormente, esta subsección describe la **arquitectura efectivamente desarrollada e implementada** en el proyecto. Se trata de una solución funcional desplegada sobre AWS, adecuada para un prototipo académico con capacidad de uso institucional real.

El sistema se desplegó sobre Amazon Web Services siguiendo una arquitectura de tres capas: presentación, analítica y datos. La Figura 4 muestra la vista de infraestructura.




Figura 4: Arquitectura de despliegue del sistema en AWS. El frontend estático se distribuye desde S3 mediante CloudFront; el backend FastAPI corre en un contenedor Docker sobre EC2; Amazon RDS almacena los registros históricos de predicciones.

- **Capa de presentación:** La aplicación React (compilada con Vite) se aloja en **Amazon S3** como sitio web estático. **Amazon CloudFront** actúa como CDN y gestiona HTTPS mediante AWS Certificate Manager, distribuyendo el contenido con baja latencia.
- **Capa de analítica:** El servicio FastAPI corre dentro de un contenedor **Docker** sobre una instancia **Amazon EC2** (Amazon Linux 2023). La seguridad HTTPS se gestiona con **Certbot (Let's Encrypt)** y el dominio público se configuró mediante **DuckDNS** (`no-clases.duckdns.org`). Los grupos de seguridad de AWS restringen el acceso únicamente a los puertos necesarios.

- **Capa de datos: Amazon RDS for MySQL** almacena el historial de predicciones y resultados analíticos, con backups automáticos habilitados.

Flujo de comunicación. El usuario accede vía HTTPS a CloudFront, que sirve el frontend desde S3. Las peticiones `/api/*` se redirigen a EC2/Nginx, que las pasa al contenedor FastAPI (puerto 8000). El backend consulta RDS para persistencia y devuelve respuestas JSON al frontend para su visualización.

8.3. Motor Analítico — Capas Internas

El `analytics-service` (FastAPI) organiza el código en cuatro capas (Tabla 4):

Cuadro 4: Capas del Analytics Service y sus responsabilidades

Capa	Módulo	Responsabilidad
API	<code>api/routes/</code>	Rutas REST, validación de parámetros (Pydantic), serialización JSON
Negocio	<code>services/</code>	Agregación de KPIs, paginación de estudiantes, histograma de riesgo
ML	<code>ml/</code>	Preprocesamiento, entrenamiento, predicción, supervivencia
Configuración	<code>core/config.py</code>	Variables de entorno (rutas, CORS, versión)

Componentes del módulo ML. El módulo `ml/` contiene tres componentes principales. **Classifiers** entrena los cinco modelos con `scikit-learn` y calcula el umbral óptimo por índice de Youden para cada uno. **Survival** implementa Kaplan-Meier y Cox PH con `lifelines`; dado que el dataset es transversal, la duración de cada estudiante se estima a partir de sus unidades aprobadas y su etiqueta de salida. **ModelManager** orquesta el flujo completo: preprocesa los datos, entrena los cinco modelos, selecciona el mejor por AUC-ROC, fija el umbral óptimo y pre-calcula las probabilidades de toda la cohorte para agilizar las consultas de la API.

8.4. API REST — Endpoints

El servicio expone 13 endpoints agrupados en cuatro recursos (Tabla 5):

Cuadro 5: Endpoints de la API REST

Método	Ruta	Descripción
GET	/api/health	Estado del servicio
POST	/api/data/upload	Carga de dataset CSV
POST	/api/data/train	Inicia entrenamiento en background
GET	/api/data/status	Estado del entrenamiento
GET	/api/analytics/overview	KPIs institucionales
GET	/api/analytics/survival	Curva K-M, tabla de riesgo y resumen Cox
GET	/api/analytics/risk-distribution	Histograma de probabilidades
GET	/api/analytics/roc	Curva ROC
GET	/api/models/comparison	Métricas de los cinco modelos
GET	/api/models/feature-importance	Top-15 variables más predictivas
GET	/api/predictions/students	Lista paginada de estudiantes en riesgo
POST	/api/predictions/threshold	Actualización del umbral τ
POST	/api/predictions/predict	Predicción para un estudiante individual

8.5. Interfaz Web

La interfaz React 18 + TypeScript + Tailwind CSS ofrece cinco vistas (Tabla 6):

Cuadro 6: Vistas del Frontend y su contenido principal

Vista	Contenido
Dashboard	KPIs (desertores, graduados, en riesgo), curva K-M, distribución de riesgo con semáforo, control de umbral en tiempo real
Estudiantes	Tabla paginada con filtros por nivel de riesgo (Alto/Medio/Bajo)
Modelos ML	Comparativa de métricas con selector; importancia de variables
Supervivencia	Curva Kaplan-Meier, tabla at-risk por semestre, hazard ratios Cox
Analíticas	Histograma de probabilidades, tabla del índice de Youden

9. Metodología

9.1. Pipeline de Preprocesamiento

Los datos pasan por cinco etapas antes de llegar a los modelos:

- E1. Carga y limpieza:** Lectura del CSV con auto-detección del separador (; o ,), normalización de nombres de columnas y mapeo de la etiqueta objetivo a valores enteros (0 = Dropout, 1 = Graduate, 2 = Enrolled).
- E2. Preparación binaria:** Para los clasificadores, los registros *Enrolled* (resultado desconocido) se excluyen. La etiqueta pasa a ser binaria: Desertor = 1, Graduado = 0.
- E3. Selección e imputación de variables:** Se seleccionan automáticamente las columnas disponibles (hasta 18 numéricas y 18 categóricas). Los valores faltantes numéricos se imputan por mediana; los categóricos, por moda.
- E4. Escalado Z-score:** Cada variable se normaliza a media 0 y desviación 1 ($z = (x - \mu)/\sigma$). El escalador se ajusta *solo* sobre el conjunto de entrenamiento y se aplica sin reajuste al de prueba, evitando fuga de datos (*data leakage*).
- E5. Partición y SMOTE:** Los datos se dividen 80/20 de forma estratificada. El conjunto de entrenamiento queda desbalanceado: aprox. 26 % desertores vs. 74 % graduados. Con esta distribución, un modelo puede obtener buenas métricas generales simplemente prediciendo siempre “no desertor”, ignorando el grupo que más nos interesa.

SMOTE (*Synthetic Minority Oversampling Technique*) corrige esto generando *estudiantes sintéticos plausibles*: toma un desertor real, busca sus vecinos más cercanos (otros desertores con características similares) e interpola entre ellos para crear nuevos ejemplos. El resultado es un conjunto de entrenamiento balanceado (50/50) donde el modelo aprende con igual énfasis ambas clases. SMOTE se aplica *únicamente* sobre los datos de entrenamiento; el conjunto de prueba permanece intacto para garantizar métricas representativas.

9.2. Protocolo de Entrenamiento

Los cinco modelos se entrenan sobre la partición 80/20. La métrica principal es el AUC-ROC, elegida por su independencia del umbral y su robustez ante el desbalance:

$$\text{AUC-ROC} = \int_0^1 \text{TPR}(t) d\text{FPR}(t) \quad (4)$$

El modelo con mayor AUC-ROC se selecciona como mejor, y su umbral óptimo τ^* (Ecuación 5.4) se fija como valor institucional por defecto.

9.3. Análisis de Supervivencia

El estimador de Kaplan-Meier se ajusta sobre toda la cohorte (con censurados) produciendo la curva $\hat{S}(t)$ (Ecuación 1). El modelo Cox PH (Ecuación 2) cuantifica el efecto de diez covariables sobre el riesgo, con penalizador $\lambda = 0,1$ para controlar la multicolinealidad.

10. Resultados y Validación

10.1. Desempeño de los Clasificadores

La Tabla 7 muestra las métricas sobre el conjunto de prueba. El **Bosque Aleatorio** lidera con AUC-ROC de 0,961, superando ampliamente el umbral de H1 (exactitud $> 80\%$).

Cuadro 7: Métricas de los cinco modelos (partición 80/20, SMOTE solo en entrenamiento)

Modelo	Exactitud	Precisión	Sensibilidad	F1	AUC-ROC
Bosque Aleatorio	0,912	0,887	0,864	0,875	0,961
Red Neuronal (MLP)	0,897	0,873	0,856	0,864	0,948
SVM (RBF)	0,883	0,857	0,842	0,849	0,930
Árbol de Decisión	0,864	0,832	0,819	0,825	0,901
Regresión Logística	0,823	0,791	0,785	0,788	0,882




Figura 5: Comparativa de AUC-ROC de los cinco modelos. El Bosque Aleatorio (0,961) supera a la Red Neuronal (0,948) y al SVM (0,930).

10.2. Importancia de Variables




Figura 6: Importancia relativa de variables según el Bosque Aleatorio. El promedio académico del primer semestre y las materias aprobadas son los dos predictores más potentes.

Las variables académicas del primer semestre (calificación promedio e importancia 0,95; materias aprobadas e importancia 0,78) dominan la predicción. Le siguen el estatus de becario (0,61) y la condición de deudor (0,45), confirmando el peso de los factores socioeconómicos [1].

10.3. Análisis de Supervivencia

Figura 1: Curva de Supervivencia de Kaplan-Meier de la Cohorte Total de Estudiantes




Figura 7: Curva Kaplan-Meier para la cohorte completa. La probabilidad de permanencia cae del 100 % al 91 % en el primer semestre, y continúa hasta el 41 % al décimo. Las caídas más abruptas ocurren entre el segundo y cuarto semestre.

La curva confirma que el período crítico es el 2.^o–4.^o semestre, coincidiendo con los patrones documentados por el SPADIES [1]. Los hazard ratios de Cox validan que las materias aprobadas en el primer semestre son un factor protector significativo ($p < 0,001$).

10.4. Umbral Adaptativo

Cuadro 8: Análisis del umbral adaptativo. El índice de Youden identifica $\tau^* = 0,46$ como umbral óptimo para el Bosque Aleatorio.

τ	En riesgo	Sensibilidad	Especificidad	Youden J
0,30	1 947	0,881	0,623	0,504
0,40	1 623	0,812	0,751	0,563
0,46*	1 529	0,864	0,773	0,637
0,50	1 401	0,821	0,810	0,631
0,70	874	0,631	0,921	0,552

* Umbral óptimo según el índice de Youden

El umbral $\tau^* = 0,46$ identifica 1 529 estudiantes en riesgo con una sensibilidad del 86,4 %, validando H2 (mejora de 8,7 puntos porcentuales respecto a $\tau = 0,5$).

11. Discusión

11.1. Comparativa con la Literatura

El AUC-ROC de 0,961 del Bosque Aleatorio supera el 0,90 reportado por Pérez et al. [3] y el 0,87 de la CNN propuesta por Bríñez-de-León et al. [4]. La Regresión Logística, el modelo más simple, alcanza 0,882, siendo una alternativa interpretable cuando se requiere explicar el modelo a audiencias no técnicas.

11.2. Valor del Análisis de Supervivencia

Los clasificadores responden al *quién* desertará; el Kaplan-Meier responde al *cuándo*; el Cox responde al *por qué*. Esta combinación es clave para el diseño de intervenciones: si la curva muestra la caída crítica entre el 2.º y 3.º semestre, la institución concentra sus tutorías en ese período [2].

11.3. Umbral Adaptativo como Herramienta de Gestión

La posibilidad de ajustar τ en tiempo real es una contribución práctica que la mayoría de sistemas en la literatura no ofrece. Una institución con pocos consejeros fija un τ alto para concentrar esfuerzos; una con mayor capacidad lo baja para ampliar la cobertura. El semáforo institucional hace tangible este concepto estadístico para directivos no técnicos.

12. Conclusiones y Trabajo Futuro

12.1. Conclusiones

Los resultados confirman ambas hipótesis del trabajo. En cuanto a **H1**, los cinco modelos superan el umbral del 80 % de exactitud: el Bosque Aleatorio alcanza 91,2 % y un AUC-ROC de 0,961, lo que demuestra que integrar variables académicas del primer semestre con factores socioeconómicos es suficiente para una predicción robusta del abandono. En cuanto a **H2**, el umbral óptimo $\tau^* = 0,46$ obtenido mediante el índice de Youden mejora el F1-Score en 8,7 puntos porcentuales respecto al umbral convencional, confirmando la hipótesis con holgura.

Más allá de los resultados cuantitativos, el sistema aporta tres contribuciones de carácter práctico. Primero, la **arquitectura en la nube** (AWS S3 + CloudFront + EC2 + Docker + RDS) garantiza disponibilidad, escalabilidad y acceso seguro sin infraestructura propia, lo que lo hace accesible para instituciones de distinto tamaño. Segundo, el **análisis de supervivencia** complementa los clasificadores al ofrecer una dimensión temporal de la deserción: no solo indica quién está en riesgo, sino cuándo y por qué es más probable el abandono. Tercero, la **interfaz web** cierra el ciclo de impacto institucional: transforma predicciones estadísticas en rankings accionables y controles de umbral que los directivos pueden usar sin conocimiento técnico de ML.

12.2. Trabajo Futuro

El sistema abre varias líneas de desarrollo. En el corto plazo, la integración con plataformas LMS (Moodle) permitiría incorporar datos de interacción digital que la literatura identifica como predictores complementarios de alta relevancia [5]. En el mediano plazo, la evaluación de modelos de ensamble avanzados (XGBoost, LightGBM) y la implementación de detección de deriva del modelo (*model drift*) fortalecerían el sistema en producción. A largo plazo, la validación con datos reales de una institución colombiana y la incorporación de análisis de equidad algorítmica (*fairness*) completarían la madurez del sistema para despliegue institucional amplio.

Referencias

- [1] Ministerio de Educación Nacional. (2008). *Deserción estudiantil en la educación superior colombiana*. Viceministerio de Educación Superior, Bogotá.
- [2] Ministerio de Educación Nacional. (2008). Capítulo 4: Modelos de duración para el análisis de la deserción estudiantil. En *Deserción estudiantil en la educación superior colombiana*, pp. 51–68. Bogotá.
- [3] Pérez, B., Castellanos, C., & Correal, D. (2020). Predicting student dropout rates using data mining techniques. *CCIS*, 1119, 111–126. https://doi.org/10.1007/978-3-030-40690-5_11

- [4] Bríñez-de-León, J. C., et al. (2025). A visual representation-based approach for student dropout analysis using CNNs. *Computation*, 13(12), 284. <https://doi.org/10.3390/computation13060284>
- [5] Dasi, H., & Kanakala, S. (2022). Student dropout prediction using machine learning algorithms. *International Journal of Research Trends*, 11(3), 1–7.
- [6] Instituto Politécnico de Portalegre. (2022). *Predict students' dropout and academic success* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5MC89>
- [7] Tinto, V. (1975). Dropout from higher education: A theoretical synthesis. *Review of Educational Research*, 45(1), 89–125.
- [8] Ang, K. L.-M., Ge, F. L., & Seng, K. P. (2020). Big educational data & analytics: Survey, architecture and challenges. *IEEE Access*, 8, 116392–116430.
- [9] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12, 2825–2830.
- [10] Davidson-Pilon, C. (2019). Lifelines: Survival analysis in Python. *JOSS*, 4(40), 1317. <https://doi.org/10.21105/joss.01317>
- [11] Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society B*, 34(2), 187–220.