

Predicción del Abandono Estudiantil basada en Machine Learning: Un Análisis desde el Contexto Colombiano

Juan Pablo Nieto Cortés
Juan Sebastián Buitrago Piñeros
Ángel Cuervo

Febrero 2026

Resumen

El abandono estudiantil en instituciones de educación superior (IES) representa un problema académico, social y económico de alto impacto, con tasas en Colombia que históricamente rondan el 47 % (Ministerio de Educación Nacional, 2008). La identificación temprana de estudiantes en riesgo es fundamental para diseñar estrategias de intervención oportunas que mejoren las tasas de retención. En este trabajo se propone el diseño de un sistema predictivo basado en técnicas de Machine Learning (ML) que permita estimar la probabilidad de abandono estudiantil. La investigación se fundamenta en la revisión de trabajos previos en minería de datos educativa (Pérez et al., 2020; Dasi & Kanakala, 2022), el marco teórico institucional colombiano (Ministerio de Educación Nacional, 2008) y enfoques computacionales avanzados como la representación visual de datos estructurados (Bríñez-de-León et al., 2025). Se plantea la hipótesis de que un modelo predictivo, entrenado con datos del primer semestre, puede superar el 80 % de precisión, ofreciendo una herramienta viable para la gestión institucional. Este documento presenta la propuesta conceptual del sistema y el estado del arte asociado al problema.

1. Introducción

El abandono estudiantil constituye uno de los principales desafíos de las instituciones de educación superior a nivel mundial. En Colombia, esta problemática es particularmente crítica. Según el Ministerio de Educación Nacional (2008, p. 7), "La magnitud de la deserción estudiantil en Colombia —47 % para el período 2002-2007—, aunque cercana al promedio latinoamericano —50 %—, constituye un reto para el sistema de educación superior". Esta deserción no solo implica pérdidas económicas para las instituciones y las familias, sino que también afecta la movilidad social y la productividad del país (Ministerio de Educación Nacional, 2008, p. 17).

Diversos estudios han demostrado que factores académicos, demográficos y socioeconómicos influyen directamente en la permanencia estudiantil. El modelo de Tinto (1975, citado en Ministerio de Educación Nacional, 2008, p. 21), uno de los más aceptados, sostiene que la deserción está fuertemente relacionada con el grado de integración académica y social del estudiante en la universidad. Sin embargo, muchas instituciones carecen de mecanismos automatizados que permitan identificar tempranamente a los estudiantes en riesgo, reaccionando generalmente cuando el abandono ya es un hecho.

En este trabajo, se propone el diseño de un sistema predictivo basado en técnicas de aprendizaje automático (Machine Learning) que permita estimar la probabilidad de abandono estudiantil. La propuesta se apoya en la creciente literatura que demuestra la eficacia de estas técnicas. Como señalan Pérez et al. (2020, p. 112), "La identificación temprana de los estudiantes que están en riesgo de abandonar es fundamental para el éxito de cualquier estrategia de retención". La investigación utilizará información disponible desde el momento de la matrícula y, crucialmente, el desempeño del primer semestre académico, ya que, como lo evidencia el SPADIES, "en el segundo semestre (acumulado de 27%) se está produciendo el 59% del total de la deserción, por lo cual es crítico enfrentar el abandono de estudios en los primeros semestres" (Ministerio de Educación Nacional, 2008, p. 46).

2. Planteamiento del Problema

Las instituciones educativas suelen reaccionar ante la deserción una vez que el estudiante ya ha abandonado sus estudios, lo que limita la posibilidad de realizar intervenciones tempranas y efectivas. Esta falta de proactividad se debe, en parte, a la complejidad del fenómeno y a la ausencia de herramientas analíticas integradas en la gestión institucional.

El problema central que aborda este trabajo es:

¿Es posible predecir el riesgo de abandono estudiantil en una institución de educación superior colombiana utilizando variables académicas y socioeconómicas disponibles durante el primer semestre?

La importancia de resolver esta pregunta radica en su potencial para transformar la gestión académica. Un modelo predictivo confiable permitiría a las instituciones pasar de una postura reactiva a una preventiva. Al identificar a los estudiantes con alta probabilidad de desertar, se pueden diseñar e implementar estrategias de apoyo personalizadas, como tutorías académicas, apoyo financiero o psicológico, justo cuando son más necesarias. Esta visión es compartida por Dasi y Kanakala (2022, p. 1), quienes afirman que "si podemos reconocer las señales tempranas de abandono y prestarles atención, la tasa de abandono estudiantil se reducirá".

3. Objetivo General

Diseñar un sistema predictivo basado en técnicas de Machine Learning que permita identificar estudiantes en riesgo de abandono en una institución de educación superior colombiana, utilizando datos académicos y socioeconómicos.

4. Objetivos Específicos

- Analizar las variables académicas y socioeconómicas más relevantes asociadas al abandono estudiantil, a partir de la revisión de la literatura y estudios previos como el SPADIES (Ministerio de Educación Nacional, 2008).
- Construir y comparar el desempeño de múltiples modelos de Machine Learning (e.g., Regresión Logística, Random Forest, XGBoost) para estimar la probabilidad de deserción, siguiendo metodologías como las empleadas por Pérez et al. (2020) y Dasi & Kanakala (2022).
- Evaluar el desempeño de los modelos mediante métricas cuantitativas robustas (precisión, recall, F1-score, AUC-ROC), prestando especial atención a la minimización de falsos negativos (estudiantes en riesgo no detectados).
- Proponer una arquitectura conceptual para la integración del sistema predictivo en los flujos de trabajo institucionales, facilitando su uso por parte de administradores académicos y personal de bienestar universitario.

5. Hipótesis

Se plantea la siguiente hipótesis de investigación:

H1: Es posible predecir el abandono estudiantil con una precisión superior al 80 % utilizando un modelo de Machine Learning entrenado con variables académicas del primer semestre (como el promedio de calificaciones y el número de materias perdidas) combinadas con factores socioeconómicos (como el estrato y el nivel educativo de los padres).

Esta hipótesis se fundamenta en los resultados de estudios previos. Por ejemplo, Pérez et al. (2020, p. 120) demostraron que con un modelo de Random Forest se podía alcanzar un AUC-ROC de 0.91 ya desde el tercer semestre. De manera similar, Dasi y Kanakala (2022, p. 4) reportaron precisiones superiores al 92 % con diversos clasificadores. El SPADIES también respalda esta hipótesis al identificar que el capital cultural y académico con el cual ingresan los estudiantes a la educación superior.^{es} el principal factor determinante (Ministerio de Educación Nacional, 2008, p. 7).

6. Descripción del Dataset Propuesto

Para el desarrollo y validación del sistema predictivo, se propone utilizar el dataset público "Predict students' dropout and academic success", disponible en la plataforma Kaggle (The Devastator, 2023). La elección de este dataset se justifica por su riqueza, relevancia y alineación con las variables identificadas como clave en la literatura revisada.

6.1. Origen y Composición de los Datos

Este dataset proporciona una visión integral de estudiantes matriculados en diversos programas de pregrado en una institución de educación superior. Incluye datos demográficos, factores socioeconómicos e información de rendimiento académico, lo que permite analizar los posibles predictores del abandono y el éxito académico (The Devastator, 2023). La base de datos contiene información de múltiples cohortes y es especialmente valiosa porque incluye el rendimiento detallado del primer semestre, un periodo crítico para la deserción temprana (Ministerio de Educación Nacional, 2008).

6.2. Variables del Dataset

El dataset se compone de 35 variables que se pueden clasificar en las siguientes categorías, fundamentales según el marco teórico de Tinto (1975) y los hallazgos del SPADIES (Ministerio de Educación Nacional, 2008):

- **Variables Demográficas:** Edad al momento de la matrícula, género, estado civil, nacionalidad y si el estudiante es desplazado o internacional.
- **Variables Socioeconómicas:** Cualificación y ocupación de la madre y el padre, si el estudiante es beneficiario de beca, si es deudor, y si tiene sus tasas de matrícula al día.
- **Variables de Admisión y Contexto:** Modo y orden de aplicación, curso elegido, asistencia (diurna/nocturna), cualificación previa, y si tiene necesidades educativas especiales.
- **Variables Académicas (Primer Semestre):** Número de unidades curriculares en el primer semestre que fueron *acreditadas*, *matriculadas*, *evaluadas* y *aprobadas*. Esta granularidad es crucial, ya que permite calcular indicadores de rendimiento temprano.
- **Variables Macroeconómicas (Contexto Regional):** Tasa de desempleo, tasa de inflación y Producto Interno Bruto (PIB) de la región. La inclusión de estas variables es una de las grandes fortalezas del dataset, ya que permite investigar cómo los factores económicos externos influyen en la deserción (The Devastator, 2023), un punto señalado en estudios como el de la Universidad de Antioquia (Ministerio de Educación Nacional, 2008, p. 68), que encontró que el deterioro del mercado laboral influye negativamente en la permanencia.

6.3. Variable Objetivo

La variable dependiente o "target"^{es} la situación final del estudiante, la cual se categoriza en tres estados: "Graduado", "Desertor" y "Matriculado" (The Devastator, 2023). Para los fines de nuestro problema de clasificación binaria, esta variable se puede transformar en una variable dicotómica (Desertor / No Desertor), donde "No Desertor" agrupa a los estudiantes graduados y a los que continúan matriculados, siguiendo un enfoque similar al utilizado en los estudios de Pérez et al. (2020) y Dasi & Kanakala (2022).

El uso de este dataset público no solo permite la reproducibilidad de los experimentos, sino que también ofrece un campo de prueba rico y complejo que refleja la naturaleza multifactorial del fenómeno de la deserción, tal como se describe en la literatura.

7. Estado del Arte

La predicción del abandono estudiantil es un área de investigación activa y consolidada dentro de los campos de la minería de datos educativa (Educational Data Mining) y el aprendizaje analítico (Learning Analytics). A continuación, se revisan los fundamentos teóricos, las técnicas y los hallazgos clave de estudios precedentes, estructurando el análisis en torno a los elementos centrales de nuestra propuesta: las variables predictoras y los métodos de machine learning empleados.

7.1. Fundamentos Teóricos y Definición del Problema

El modelo de integración estudiantil de Vincent Tinto (1975) sigue siendo el marco teórico más influyente. Este modelo postula que la decisión de un estudiante de abandonar sus estudios está fuertemente relacionada con su grado de integración académica (rendimiento y desarrollo intelectual) y social (interacciones con compañeros y profesores) dentro de la institución (Ministerio de Educación Nacional, 2008, p. 22). Operacionalmente, el Ministerio de Educación Nacional de Colombia define como desertor a "aquel individuo que siendo estudiante de una institución de educación superior no presenta actividad académica durante dos semestres académicos consecutivos" (Ministerio de Educación Nacional, 2008, p. 18), una definición que ha sido la base para el desarrollo del sistema SPADIES y que utilizaremos como referencia conceptual para nuestro modelo.

7.2. Variables Predictivas: Consensos y Hallazgos Clave

La literatura presenta un consenso amplio sobre las categorías de variables que influyen en la deserción.

- **El contexto colombiano y el SPADIES:** En Colombia, el estudio fundacional realizado para el SPADIES identificó que el "principal factor

determinante del abandono de estudios... se sitúa en la dimensión académica: está asociado al potencial o capital cultural y académico con el cual ingresan los estudiantes” (Ministerio de Educación Nacional, 2008, p. 7). Le siguen en importancia los factores financieros y socioeconómicos. Este estudio, que analizó a 800.000 estudiantes, utilizó modelos de duración (análisis de supervivencia) para demostrar que variables como el puntaje en las pruebas ICFES, la tasa de repitencia, el ingreso familiar y el nivel educativo de los padres son determinantes críticos (Ministerio de Educación Nacional, 2008, p. 68).

- **Estudios de Caso en Pregrado:** Investigaciones más recientes en programas específicos refuerzan estos hallazgos. Pérez et al. (2020), en su estudio con estudiantes de Ingeniería de Sistemas en una universidad colombiana, utilizaron un enfoque de *feature engineering* para agregar datos de rendimiento por área de conocimiento. Descubrieron que las variables más predictivas eran el promedio en materias de ingeniería de sistemas, el número de materias perdidas en estas mismas asignaturas y el promedio acumulado (GPA). Asimismo, encontraron una fuerte correlación entre el rendimiento en asignaturas de ingeniería y el de matemáticas y física (Pérez et al., 2020, p. 119). Esto subraya la importancia de variables académicas detalladas, como las disponibles en el dataset de Kaggle (e.g., unidades curriculares aprobadas en el primer semestre).
- **Variables de Interacción y Contexto:** Dasi y Kanakala (2022) enfatizan el poder predictivo de las variables que reflejan la interacción del estudiante con el entorno de aprendizaje. En su modelo, las variables más significativas fueron el número de accesos a la plataforma virtual, los resultados en tests y la entrega de asignaciones (Dasi & Kanakala, 2022, p. 3). Por otro lado, el dataset de Kaggle (The Devastator, 2023) introduce una dimensión adicional poco explorada en los estudios anteriores: las variables macroeconómicas (tasa de desempleo, inflación, PIB). Esto permitiría contrastar hallazgos como los del SPADIES, que indican que “el deterioro del mercado laboral influye negativamente sobre la permanencia del estudiante” (Ministerio de Educación Nacional, 2008, p. 68).

7.3. Técnicas de Machine Learning: De lo Clásico a lo Innovador

La evolución de las técnicas de machine learning ha permitido abordar el problema de la deserción con una precisión y profundidad crecientes.

- **Modelos Clásicos y de Ensemble:** La mayoría de los estudios han utilizado y comparado una batería de clasificadores. Dasi y Kanakala (2022) evaluaron seis algoritmos (Regresión Logística, SVM, Naive Bayes, Árbol de Decisión, Redes Neuronales y Random Forest) en un dataset con 261 registros, encontrando que todos superaban el 92% de precisión, aunque los autores advierten sobre la necesidad de interpretar estos resultados

con cautela debido al pequeño tamaño de la muestra (Dasi & Kanakala, 2022, p. 5). Pérez et al. (2020), con un dataset más grande (762 estudiantes), compararon Árboles de Decisión, Regresión Logística, Naive Bayes y Random Forest, concluyendo que Random Forest y la Regresión Logística ofrecían los mejores resultados, con valores de AUC-ROC que superaban el 0.90 a partir del tercer semestre (Pérez et al., 2020, p. 120). Estos estudios demuestran la eficacia y madurez de los modelos de ensemble para esta tarea.

- **Innovación en la Representación de Datos:** Un enfoque radicalmente diferente es el propuesto por Bríñez-de-León et al. (2025). Para superar las limitaciones de los modelos tradicionales con datos de baja dimensionalidad, su metodología transforma los datos estructurados de los estudiantes en imágenes sintéticas. Cada variable se mapea a una distribución Gaussiana, cuya amplitud y anchura representan el valor y la importancia de la variable, respectivamente. Luego, estas superficies Gaussianas se modulan con una función coseno para generar “imágenes de franjas” (*fringe patterns*) que codifican relaciones complejas entre variables (Bríñez-de-León et al., 2025, p. 17). Una red neuronal convolucional (CNN) entrenada desde cero con estas imágenes superó a los modelos de ML clásicos y a las arquitecturas de aprendizaje por transferencia (como VGG16 o ResNet50), demostrando el enorme potencial de explorar nuevas representaciones para mejorar tanto la precisión (Accuracy de 0.87) como la interpretabilidad del modelo (Bríñez-de-León et al., 2025, p. 23).

En resumen, el estado del arte confirma la viabilidad de construir modelos predictivos de deserción con alta precisión. La literatura respalda el uso de un conjunto diverso de variables (académicas, socioeconómicas y de contexto) y ofrece un abanico de técnicas, desde los ya probados modelos de ensemble como Random Forest, hasta enfoques innovadores de deep learning con representación visual de datos. Nuestra propuesta se basa en este conocimiento para diseñar un sistema que, utilizando un dataset rico y público, explore y compare diferentes metodologías, contribuyendo así al avance del campo.

8. Propuesta del Sistema

Se propone el desarrollo de un sistema compuesto por los siguientes componentes, tomando como referencia las mejores prácticas identificadas en la literatura:

- **Ingesta y preprocesamiento de datos:** Recolección, limpieza e integración de variables académicas y socioeconómicas de los estudiantes. Este paso es crucial, ya que, como advierten Bríñez-de-León et al. (2025, p. 2), los datos institucionales en Colombia “no fueron diseñados originalmente con fines de analítica predictiva; requieren una extensa fase de preprocesamiento para armonizar, limpiar e integrar los datos”.

- **Modelo predictivo:** Implementación y comparación de múltiples modelos de Machine Learning (Regresión Logística, Random Forest, XGBoost) para estimar la probabilidad de abandono. Se explorará la posibilidad de implementar enfoques más avanzados como las representaciones visuales propuestas por Bríñez-de-León et al. (2025).
- **API de consulta:** Desarrollo de un servicio (API REST) que permita a otros sistemas institucionales realizar predicciones en tiempo real o por lotes.
- **Panel administrativo (Dashboard):** Interfaz gráfica que visualice a los estudiantes clasificados por nivel de riesgo (alto, medio, bajo), permita la consulta de métricas agregadas y facilite la generación de informes para la toma de decisiones por parte de directivos, docentes y personal de bienestar universitario.

El sistema permitirá a la institución pasar de una gestión reactiva a una proactiva, enfocando los recursos de apoyo en los estudiantes que más lo necesitan, justo a tiempo para marcar una diferencia en su trayectoria académica.

9. Conclusiones Preliminares

El abandono estudiantil en la educación superior colombiana es un problema complejo y multifactorial, pero que puede abordarse eficazmente mediante técnicas de análisis predictivo. La literatura revisada demuestra que es posible construir modelos de Machine Learning con alta capacidad para identificar tempranamente a los estudiantes en riesgo, utilizando variables académicas y socioeconómicas.

La propuesta presentada establece las bases conceptuales para el desarrollo de un sistema inteligente de alerta temprana. La principal fortaleza de este enfoque radica en su potencial para proporcionar a las instituciones una herramienta basada en evidencia que permita optimizar la asignación de recursos y diseñar intervenciones personalizadas, con el objetivo último de mejorar las tasas de retención y graduación, y así contribuir a los objetivos de política educativa nacional (Ministerio de Educación Nacional, 2008, p. 8).

En las siguientes etapas del proyecto se desarrollará la arquitectura detallada, se realizará la implementación y comparación de los modelos propuestos, y se evaluará cuantitativamente su desempeño, contribuyendo así al campo de la analítica del aprendizaje en el contexto colombiano.

Referencias

- [1] Ministerio de Educación Nacional (2008). *Deserción estudiantil en la educación superior colombiana: Elementos para su diagnóstico y tratamiento*. Bogotá: Ministerio de Educación Nacional.

- [2] Pérez, B., Castellanos, C., & Correal, D. (2020). Predicting student dropout rates using data mining techniques: A case study. En *Communications in Computer and Information Science* (Vol. 1119, pp. 111-126). Springer.
- [3] Bríñez-de-León, J. C., Patiño-Hernández, A. E., Cardona-Orozco, G. J., Restrepo-Londoño, F. A. (2025). A visual representation-based approach for student dropout analysis. *Computation*, 13(12), 284.
- [4] Dasi, H., & Kanakala, S. (2022). Student dropout prediction using machine learning techniques. *International Journal of Recent Technology and Engineering*, 11(3), 1-7.
- [5] The Devastator (2023). Predict students' dropout and academic success [Conjunto de datos]. Kaggle. Disponible en: <https://www.kaggle.com/datasets/thedevastator/predicting-student-dropout-and-academic-su>