

Modelamiento de la Deserción Universitaria en la Universidad Cooperativa de Colombia Sede Villavicencio Mediante Algoritmos de Machine Learning



**Universidad Cooperativa
de Colombia**

**Miguel Ángel Galvis Martínez
783709**

**Universidad Cooperativa de Colombia
Facultad de Ingeniería
Ingeniería de Sistemas
Villavicencio, Meta
Abril – 2024**

Modelamiento de la Deserción Universitaria en la Universidad Cooperativa de Colombia Sede Villavicencio Mediante Algoritmos de Machine Learning



**Universidad Cooperativa
de Colombia**

**Miguel Ángel Galvis Martínez
783709**

Asesores

**Manuel Arturo Nova Martínez
Yerson Ferney Porras García**



**Universidad Cooperativa de Colombia
Facultad de Ingeniería
Ingeniería de Sistemas
Villavicencio, Meta
Abril – 2024**

Resumen

En esta investigación de trabajo de grado de pregrado se recolectaron registros de datos socioeconómicos, personales y de percepción académica de estudiantes activos de la facultad de ingeniería de la Universidad Cooperativa de Colombia sede Villavicencio, los cuales por medio de un proceso de limpieza y análisis exploratorio se adecuaron con el objetivo de entrenar modelos computacionales de Random Forest para determinar la probabilidad de que un estudiante abandone sus estudios académicos.

En este documento en primer lugar se realiza una descripción sobre lo que es la deserción basada en datos y estudios nacionales como internacionales y se contextualiza la problemática en Colombia, posteriormente se explican los conceptos que se usaran en esta investigación tales como machine learning, data mining, modelos computacionales, métricas de evaluación, entre otros.

Luego se detalla el procedimiento del trabajo que se realizó en la recolección de más de 800 registros de estudiantes por medio de una serie de encuestas realizadas en los periodos académicos 2023-10 y 2023-20, con más de 45 preguntas, donde se tomó una muestra de 483 estudiantes que pertenecen a la facultad de ingeniería la cual está conformada por ingeniería de sistemas e ingeniería civil. Estos 2 datasets fueron sometidos a un análisis descriptivo con el fin de unificarlos en uno solo, en donde se aplicaron métodos de limpieza y estadísticos para ordenar la información de forma óptima para el entrenamiento de los modelos.

La parte final del trabajo se concentra en el entrenamiento de modelos computacionales basados en el Algoritmo Random Forest, el cual es implementado mediante el uso de la librería `sklearn.ensemble.RandomForestClassifier` de Python y la metodología de búsqueda amplia `GridsearchCv` mediante la librería `sklearn.model_selection.GridSearchCV` para optimización de parámetros. Bajo este dataset se determina una configuración óptima de parámetros que entrega un 46.4 % de la métrica de desempeño.

Palabras clave: Deserción, machine learning, modelos computacionales, minería de datos

Abstract

In this undergraduate thesis research, socioeconomic, personal, and academic perception data from active students of the Faculty of Engineering at the Cooperativa University of Colombia, Villavicencio campus, were collected. Through a process of data cleaning and exploratory analysis, these data were prepared with the aim of training Random Forest computational models to determine the probability of a student dropping out of their academic studies.

Firstly, this document provides a description of dropout based on national and international data and studies, and contextualizes the issue in Colombia. Subsequently, it explains the concepts used in this research such as machine learning, data mining, computational models, evaluation metrics, among others.

Then, the document details the procedure carried out for the collection of over 800 student records through a series of surveys conducted during the academic periods 2023-10 and 2023-20, with more than 45 questions. A sample of 483 students from the Faculty of Engineering, which comprises Systems Engineering and Civil Engineering, was taken. These two datasets underwent a descriptive analysis to unify them into a single dataset, where cleaning and statistical methods were applied to optimally organize the information for model training.

The final part of the work focuses on training computational models based on the Random Forest algorithm, which is implemented using Python's `sklearn.ensemble.RandomForestClassifier` library and the extensive search methodology `GridSearchCV` via the `sklearn.model_selection.GridSearchCV` library for parameter optimization. This dataset determined an optimal parameter configuration that yields a 46.4% performance metric.

Key words: Desertion, machine learning, computational models, data mining

Tabla de contenido

Contenido

I.	Introducción	9
II.	Planteamiento del problema.....	11
III.	Objetivos.....	14
IV.	Justificación	15
V.	Antecedentes	16
VI.	Marco Teórico	18
VII.	Metodología	24
VIII.	Desarrollo del trabajo.....	27
IX.	Fase de recolección de datos	27
X.	Fase de análisis y unificación de los 2 datasets (Estudio y compresión de los datos)	28
XI.	Fase de análisis, limpieza y ordenamiento de los datos	36
XII.	Análisis exploratorio de datos y correlaciones	40
XIII.	Conclusiones	54
XIV.	Referencias	56
XV.	Anexo.....	60

Lista de figuras

Fig. 1.	Factores principales de deserción según [1]	11
Fig. 2.	Representación gráfica del porcentaje de deserción en los niveles de formación universitario, técnico profesional y tecnológico. Año 2010 – 2020	12
Fig. 3.	Representación gráfica del ciclo de la metodología CRIPS.....	25
Fig. 4.	Análisis estadístico	36
Fig. 5.	Cantidad de estudiantes por carrera	40
Fig. 6.	Autopercepción de los estudiantes respecto a su carrera	41
Fig. 7.	¿Los estudiantes en algún momento han abandonado o interrumpido sus estudios?.....	41
Fig. 8.	¿Tiene hijos?.....	42
Fig. 9.	Gráfico de bigotes vs promedio académico.	43
Fig. 10.	Gráfico de barras de la motivación de los estudiantes en función si tiene o no hijos.....	44
Fig. 11.	Mapa de calor semestre vs motivación.....	45
Fig. 12.	Mapa de calor semestre vs 9 variables.....	46

Lista de tablas

TABLA I..... 28

TABLA II..... 28

TABLA III..... 31

TABLA IV 32

TABLA V 33

TABLA VI 35

TABLA VII 38

TABLA VIII 39

TABLA IX 48

TABLA X 48

TABLA XI 48

TABLA XII 49

TABLA XIII 49

I. Introducción

Esta investigación se basa en el estudio y análisis de los factores y circunstancias que influyen en los estudiantes de programas académicos universitarios que han tomado la decisión de desertar o ser posibles desertores. La educación superior es un conocimiento clave en la sustentabilidad y progreso de cada país, un país con altos niveles de educación representa desarrollo económico, innovación y una ventaja respecto a sus iguales, por esta razón es de vital importancia buscar métodos que ayuden a impulsar e incentivar a la población a prepararse en campos de investigación y desarrollo, por lo tanto, se requiere analizar los factores que representan un peligro en este proceso educativo [1]. La contribución de la educación superior a la sociedad y al desarrollo económico implica que el abandono de un estudiante tiene un impacto que va más allá de un aspecto personal. Es una afectación en el bienestar del entorno familiar, reducción en las tasas de graduación, de los retornos a la educación superior y afectación en el bienestar de los actores económicos involucrados [2]. Según las consultas realizadas en las fuentes bibliográficas [3]-[2] las principales causas de deserción en América Latina son el abandono de los estudios por la no adaptación al entorno universitario, la elección equivocada del área de estudio, factores económicos y dificultades psicológicas y emocionales. En los últimos años los factores psicológicos han aumentado de manera drástica debido a los efectos secundarios de la pandemia de Covid-19, para el año 2019 la tasa deserción universitaria se ubicaba en 8.25% y para el año 2020 esta se ubicó en 11.96% [4] demostrando que las consecuencias del confinamiento, el ingreso forzoso a la virtualidad y el fuerte golpe a la economía contribuyeron al aumento de la deserción.

La minería de datos se basa en encontrar patrones y relaciones entre información que se encuentran en bases de datos, con el fin de dar un sentido y orden a la información, así pues, de esta manera adquirir nuevos conocimientos, este proceso se realiza por medio de modelos computacionales que trabajan con Machine Learning, área la cual en los últimos años ha demostrado grandes avances en investigaciones de todo tipo, gracias a su capacidad de procesar una gran cantidad de datos, parametrizándolos y posteriormente comprendiendo su esencia para aprender de ellos y finalmente poder recibir nueva entrada y dar una clasificación o predicción muy acertada de su comportamiento. En la Universidad de Brasilia se llevó a cabo un estudio Titulado “Decision trees for predicting dropout in Engineering Course students in Brazil” en donde se investigó cual modelo computacional era más preciso al momento de clasificar e identificar a un posible estudiante desertor, en este estudio se determinó que el modelo de árboles de decisión es la mejor opción ya que los árboles de decisión generados a partir de conjuntos de datos pequeños tienen una buena generalización [1].

Esta investigación tiene como base el uso y aplicación de conocimientos en informática y estadística por medio de los conceptos de Data Mining, Machine Learning y Modelos Computacionales, soportado en el lenguaje de programación Python que nos permite manejar y transformar la información por medio de librerías para parametrizar y entrenar un modelo computacional, en esta investigación se optó por usar el modelo computacional Random Forest el cual se basa en la estructura de Decision Tree, ya que basándonos en las fuentes bibliográficas [5]-[6]-[1] se identificó que es un modelo que se acopla muy bien a este caso específico de investigación. La información se recolectó por medio de unas encuestas realizadas a estudiantes activos de la Universidad Cooperativa de Colombia sede Villavicencio (UCCV) de la facultad de Ingeniería en el periodo del año 2023. Esta información fue sometida a un proceso de análisis, limpieza, transformación y parametrización para posteriormente entrenar distintos modelos de Random Forest y así poder hallar una parametrización que nos dé como resultado un mayor nivel de asertividad, con el fin de darles un uso en la investigación en el sector de la educación.

La investigación se enfoca de específicamente en el estudio de la efectividad y asertividad de los modelos computacionales para identificar la deserción estudiantil universitaria; sus posibles causas, patrones y dejar un precedente para apoyar futuras investigaciones que busquen formas, metodologías y estrategias para identificar y mitigar la deserción estudiantil en estudios superiores.

Este documento está estructurado en 9 partes incluyendo la introducción, los cuales están conformados de la siguiente manera, en primer lugar se encontrará el planteamiento del problema: en donde se profundiza en el impacto de la deserción estudiantil y los retos que significa para el sistema educativo de Colombia y la Universidad Cooperativa de Colombia sede Villavicencio, en segundo lugar los objetivos: en esta sección se plantea el objetivo general y específicos de esta investigación, en tercer lugar la justificación: en esta sección se entra en detalle el porque es importante realizar esta investigación, en cuarto lugar los antecedentes: en esta sección se plasma el estado del arte de esta área, investigaciones relacionadas e información que nos permite consolidar buenas bases de apoyo para ejecutar esta investigación, en sexto lugar el marco teórico: en esta sección se describe todos los conceptos, técnicas y tecnologías que servirán de apoyo para el desarrollo de esta investigación, en séptimo lugar la metodología: aquí se plantea la metodología de investigación que se aplicará, en octavo lugar el desarrollo del trabajo: en esta sección se describe todo el periodo de vida de la investigación, iniciando con la recolección de datos, análisis, métodos de limpieza y transformación, posteriormente entra en una fase de entendimiento de la información con el objetivo de comprender su comportamiento y seleccionar las variables más relevantes para parametrizarlas y entrenar los modelos y finalmente obtener resultados y en novenos lugar las conclusiones: en esta sección se dan las conclusiones de la investigación

II. Planteamiento del problema

1.1 Formulación del problema

La deserción estudiantil es una problemática que se viene estudiando desde muchos años atrás. Representa grandes consecuencias a nivel económico y social en la sociedad. Según [1] las causas de la deserción se pueden clasificar en 3 factores:

- Internos: Son los factores relacionados con la salud, la familia y la motivación
- Intermedios: Son los factores sobre las relaciones de los estudiantes con su entorno académico, como sus compañeros y profesores
- Externos: Son los factores relacionados con el mundo laboral y sus elecciones de estudio profesional

A continuación, se representa en la figura 1 la relación entre los 3 factores principales.




Fig. 1. Factores principales de deserción según [1]

Nota: fuente [1]

De acuerdo con cifras oficiales del Ministerio de Educación Nacional, del Sistema Nacional de Información de la Educación Superior y observatorio de la Universidad Colombiana (MEN), en Colombia el 42% de los jóvenes ingresa a la educación superior y solo el 18% se gradúa. De acuerdo con el MEN [7] el 44% de la población, no tiene los recursos para matricularse en una universidad o simplemente no clasifica para ingresar a la educación pública; de hecho, solo el 49% de los adolescentes, entre 17 y 21 años, tiene la oportunidad de estudiar una carrera profesional [8].

El nivel de deserción aumento por el impacto que ha generado el Covid-19, se ubica en un 23,5%, según los últimos reportes de la Asociación Colombiana de Universidades [8].

Como se puede observar en la figura 2, se evidencia que para el año 2020, la tasa de deserción anual para los programas universitarios se ubicó en 8,02%, para los tecnológicos en 13,26% y para los técnicos profesionales en 13,65% [9].




Fig. 2. Representación gráfica del porcentaje de deserción en los niveles de formación universitario, técnico profesional y tecnológico. Año 2010 – 2020

Nota: fuente [9]

Como se puede apreciar en la figura 2 la deserción universitaria no ha representado una reducción notable en el transcurso los años 2010 y 2020, su reducción ha sido inferior al 2% y este logro se vio afectado por las consecuencias de la pandemia del Covid-19, ya que esta cifra aumentó al 11.96% para el año 2020 [4]. Según datos tomados de [7] del año 2013 Colombia ha implementado medidas para reducir la deserción universitaria brindando apoyo económico a las entidades públicas y créditos educativos con tasas de interés de 0% para ciertos casos especiales, créditos condonables y subsidios de sostenimiento para estudiantes de bajos recursos. Es cierto que estas medidas en su momento ayudaron a mitigar la deserción durante un periodo, sin embargo, no representa una solución de mayor impacto ya que el factor económico solo es un de las varias causas de la deserción, por esta

razón es importante observar todo el panorama e implementar medidas que permitan dar una solución con mayor alcance. En la actualidad se cuenta con poderosas herramientas que nos pueden ayudar a identificar y clasificar todas las causas de la deserción, tales como los modelos computacionales, el Machine Learning y Big Data.

Desarrollar un análisis de deserción estudiantil es un caso de estudio es complejo, más cuando se requiere elegir un modelo computacional de clasificación para dicho fenómeno. Es necesario tener en cuenta varios factores para determinar cuál es el modelo más adecuado según los resultados esperados, pues existen muchos de estos: árboles de decisión, redes neuronales, análisis discriminante, redes bayesianas y regresión logística. Actualmente, en la UCCV, no existe una guía que explique y brinde una adecuada parametrización que permita la elección de un modelo que se ajuste más la naturaleza de los datos y el contexto investigativo y académico de la universidad. Por esto mismo, se suelen implementar varios modelos computacionales para posteriormente realizar un proceso de comparación y análisis personalizado según el criterio de cada investigador [10].

Actualmente no existe un modelo de análisis de deserción estudiantil en la UCCV, por consecuencia no existe información precisa sobre el nivel de deserción, sus causas y un plan de acción para reducir la esta misma. Con la cuarta revolución industrial se ha dado paso a nuevas herramientas y tecnologías que pueden brindar mayor eficiencia al momento de realizar el proceso de toma y análisis de datos de cualquier índole, en este caso, datos socioeconómicos, geográficos, personales, educativos y demás que sean necesarios para enriquecer la información que se usará para entrenar modelos de Machine Learning y obtener un mayor porcentaje de eficiencia de predicción. Gracias a estas nuevas herramientas, se tiene una mayor variedad de modelos de clasificación y estrategias para llegar al mismo objetivo.

El MEN determina que existen 2 tipos de deserción estudiantil: deserción respecto al tiempo y deserción respecto al espacio, así mismo como lo plantea Barreno en su artículo [10], en esta investigación solo se tomara en cuenta la deserción respecto al tiempo, en la cual es necesario determinar un intervalo de periodos de ausencia para considerar una deserción. Con este estudio se busca dar respuesta a la siguiente pregunta:

¿Cómo por medio de la implementación de modelos computacionales basados en algoritmos de Machine Learning se puede llegar a un mayor grado de asertividad en la predicción de la probabilidad de deserción estudiantil en la Universidad Cooperativa de Colombia sede Villavicencio?

III. Objetivos

Objetivo general

Construir un modelo computacional para identificar la posibilidad de deserción estudiantil en la universidad Cooperativa de Colombia sede Villavicencio a través de algoritmos de Machine Learning.

Objetivos específicos

- Consolidar el conjunto de datos con información relevante de los estudiantes que permita realizar un análisis de la deserción estudiantil de la universidad Cooperativa de Colombia sede Villavicencio.
- Realizar un análisis descriptivo del conjunto de datos para identificar relaciones entre las variables involucradas.
- Entrenar y optimizar un modelo computacional basado en algoritmos de Machine Learning para identificar la posibilidad de deserción estudiantil.

IV. Justificación

Durante mucho tiempo las instituciones de educación superior han desarrollado e implementado diferentes estrategias para identificar y reducir el porcentaje de deserción estudiantil, pero, esta problemática abarca muchas variables que pueden alterar la decisión final de un estudiante al desistir de sus estudios. En la universidad Complutense de Madrid se publicó una tesis doctoral titulada “Detección de alumnos de riesgo y medición de centros escolares mediante redes neuronales” [11] del año 1999, en donde se usó información de 7454 estudiantes de educación media de los años 1984 y 1985 para entrenar redes neuronales en donde el investigador Daniel Santín Gonzáles logro demostrar que las redes neuronales tenían un buen rendimiento al momento de poder identificar a los estudiantes en riesgo de fracaso académico. Gracias al estudio y surgimiento de nuevas disciplinas y tecnologías como las Técnicas de Minería de Datos, Machine Learning y las buenas prácticas de almacenamiento, se ha logrado entrenar modelos computacionales que tienen la capacidad de predecir con un alto nivel de asertividad la probabilidad de deserción de un estudiante, lo cual abre camino muchas posibilidades de nuevas investigaciones.

A pesar de que son tecnologías y aplicaciones muy recientes, actualmente existen muchas publicaciones sobre esta investigación y su aplicación en modelos predictivos de deserción estudiantil superior, lo cual demuestra la urgencia por parte de varios actores a nivel mundial para encontrar una solución oportuna, gracias a ello existe información robusta que permite conocer al detalle procedimientos que sirven como hoja de ruta para implementar nuevas investigaciones y poder seguir alimentando el flujo de información.

En los últimos años, las instituciones de educación superior se han enfocado en mejorar sus indicadores académicos cada vez más y tener mayor impacto en la calidad y culminación de los estudios superiores, pero necesitan saber cuáles son las variables que tienen mayor incidencia en el porcentaje de deserción, ya que, esto permite atacar el problema de forma directa y efectiva [12]. En universidades colombianas como la Universidad de la Salle, se han desarrollado trabajos sobre modelos predictivos de deserción temprana implementando técnicas como los árboles de decisión [12]. Sin embargo, en la UCCV no existen este tipo de herramientas que incentiven la investigación y posibles acciones de impacto ante esta problemática.

Con esta investigación se pretende analizar modelos computacionales que se adapten mejor a este caso específico, se realizará un análisis estadístico para determinar cuáles son los factores que más tienen peso en la decisión final de los estudiantes para desertar de sus estudios, también se tendrá en cuenta la parametrización, entrenamiento del modelo y su porcentaje de eficiencia apoyándose en la matriz de confusión.

V. Antecedentes

El uso de modelos predictivos en minería de datos y aprendizaje automático se remontan a la década de 1950, cuando se desarrollaron los primeros algoritmos de aprendizaje automático y se aplicaron en la clasificación de patrones y reconocimiento de caracteres [13]. Desde entonces, la investigación en este campo ha evolucionado significativamente y ha dado lugar a una gran variedad de modelos y técnicas de análisis predictivo, sin embargo, su uso se hizo más notorio a partir de la década del 2010, década en donde el término “Minería de Datos” junto con “Big Data” empezaron a ser más utilizados y aplicados en investigaciones y modelos de negocio.

La primera investigación sobre la deserción estudiantil se llevó a cabo en la década de 1960, cuando Vicent Tinto, un académico de la universidad de Siricusa [5], desarrolló una teoría de la deserción estudiantil que se convirtió en un marco influyente para la comprensión de las causas y soluciones de la deserción en la educación superior. Vicent Tinto propuso un modelo computacional teórico que lograba identificar una gran variedad de factores que influyen en la decisión de los estudiantes de abandonar sus estudios universitarios, este modelo se fundamenta en la idea de que la deserción estudiantil se da como resultado de una interacción compleja entre muchos factores individuales que al acumularse pueden desembocar en un abandono académico [5].

En la Universidad Josip Juraj Strossmayer de Osijek, Croacia. Se realizó una investigación titulada “Árboles de decisión para predecir el éxito académico de los estudiantes” elaborada por Josip Mesarić¹ y Dario Šebalj [6]. En donde se tomó como objetivo la probabilidad de éxito de aprobar el primer año en la Facultad de Economía. Para este estudio se utilizó una muestra de 715 estudiantes del segundo año académico, los datos que se utilizaron para el entrenamiento de los modelos computacionales fueron sus registros académicos de su último año en el instituto, registros académicos del primer año en la Facultad de Economía, resultados del examen estatal entre otros datos.

En esta investigación se implementó el modelo computacional de árboles de decisión, en donde se logró obtener un modelo con un grado de asertividad del 79%, en base a ello se comprobó que las variables que tienen un mayor peso al momento de clasificar los datos fueron los resultados de la prueba estatal, la puntuación del instituto y del examen en lengua croata [6].

Entre los trabajos más recientes que se encuentran tales como [14], [15], [16] se puede observar que el estudio de la deserción académica es un problema vigente y que cada vez más se están implementando algoritmos computacionales como solución a esta problemática. En Latinoamérica también se han desarrollado investigaciones referentes al tema, en la Universidad Ricardo Palma de Perú se implementó un trabajo titulado “Diseño de un modelo predictivo basado en machine learning para el control de la deserción de estudiantes en la Universidad Ricardo Palma”, por Victor Raul de la Cruz [17]. En esta investigación se utilizó un modelo de regresión logística, ya que este permite tener un control de la deserción debido a que nos indica que las principales causas de la deserción de los estudiantes de la Universidad Ricardo Palma, eran los créditos aprobados semestrales, la deuda semestral, promedio de asistencias, ingreso económico propio y familiar [17].

Colombia no es ajena a estas investigaciones, en la Universidad Nacional Abierta y a Distancia (UNAD) se implementó un modelo titulado “Modelo de predicción de deserción estudiantil, apoyado en tecnologías de data mining, en un curso de primera matrícula de la escuela ECBTI de la UNAD” presentado en el año 2021 por Mario Luis Ávila Pérez [18]. Con esta investigación se identificaron los factores considerados por los docentes como más incidentes: la disponibilidad de tiempo, factores económicos, factores sociales, y acceso a las herramientas digitales, considerando la disponibilidad de tiempo como el factor más incidente, lo que coincide con autores como Diofanor Acevedo [19] quién encontró que el nivel socioeconómico es el principal factor asociado a la deserción. Otro elemento encontrado fue que el 53% consideró que los índices de aprobación influyen en la deserción, lo cual indica que el abandono de los estudios comienza con este síntoma que luego desemboca en el abandono mismo, relacionando directamente el rendimiento académico con retención y por ende el abandono de los estudios. Los datos obtenidos en el diagnostico apuntan a que la percepción de los docentes es positiva en cuanto al uso de la IA para la mitigación del fenómeno de la deserción, con el 84,2% de favorabilidad. Estos resultados son pertinentes toda vez que, según Antonio Berlanga [20] las técnicas Aprendizaje Automático (campo de investigación de la IA) y la Minería de datos comparten gran cantidad de técnicas, apuntando al uso de algoritmos que pueden extraer conocimiento a partir de datos [18].

En la universidad de la Salle se desarrolló una investigación sobre un modelo predictivo de deserción temprana, allí se logró concluir que la técnica más utilizada es los árboles de decisión, ya que, esta genera las características más significativas que afectan el nivel de deserción de un estudiante. Dentro de las técnicas que generan un mayor porcentaje de precisión se encuentran los árboles de decisión y las redes neuronales [12] .

Todas estas investigaciones han aportado un bloque en el camino a la solución de esta problemática social, si bien es cierto que aún no existe una solución definitiva a la deserción, por medio de la aplicación de modelos computacionales se ha logrado poder identificar los factores más relevantes y así buscar posibles soluciones que reduzcan la tasa de deserción, sin embargo, en gran parte de estos factores están ligados a características culturales, económicas y demográficas de cada caso individual, lo que significa que no existe un modelo global que dé solución a todos los casos, por esta razón es importante que la UCC desarrolle su propia investigación teniendo en cuenta las condiciones propias de su entorno.

VI. Marco Teórico

Minería De Datos

El proceso de hurgar en los datos para descubrir conexiones ocultas y predecir tendencias futuras tiene una larga historia. Conocido algunas veces como "descubrimiento de conocimientos en bases de datos", el término "minería de datos" no se acuñó sino hasta la década de 1990 [21]. La minería de datos es un proceso de descubrimiento y análisis de información útil y significativa a partir de grandes conjuntos de datos. Se trata de una técnica de análisis de datos que utiliza herramientas estadísticas, matemáticas y de inteligencia artificial para identificar patrones y relaciones ocultas dentro de los datos.

En la actualidad la minería de datos es muy usada en diferentes campos de la ciencia, como aplicaciones financieras, para emplear análisis de mercado, también en áreas de salud, educación, procesos industriales, biología, telecomunicaciones y muchas más [22]. El objetivo de la minería de datos es encontrar información valiosa y conocimientos que puedan utilizarse para tomar decisiones informadas y mejorar la eficiencia y la rentabilidad en una amplia variedad de campos, incluyendo la investigación científica, la medicina, la banca, el marketing, la seguridad y muchos otros.

El proceso de minería de datos implica la recopilación, limpieza, integración, selección, transformación y modelado de los datos para identificar patrones y relaciones significativas. Las técnicas de minería de datos más comunes incluyen la clasificación, la regresión, la segmentación, la asociación y la detección de anomalías. El proceso estándar interindustrial para la minería de datos (CRISP-DM) es una excelente guía para iniciar el proceso de minería de datos. CRISP-DM es tanto una metodología como un modelo de proceso que es neutral en cuanto al sector, la herramienta y la aplicación [22].

Machine Learning

El machine learning o aprendizaje automático es una rama de la inteligencia artificial que permite a las computadoras aprender y mejorar su desempeño en una tarea específica, sin ser explícitamente programadas para ello. En lugar de utilizar reglas y algoritmos específicos para realizar una tarea, el machine learning utiliza modelos estadísticos y de aprendizaje para analizar datos y reconocer patrones, para que la computadora pueda aprender y mejorar en la tarea a medida que se le presentan más datos [23].

El aprendizaje automático se utiliza en una amplia variedad de aplicaciones, como la clasificación de imágenes, el reconocimiento de voz, la detección de fraudes, la predicción del comportamiento del usuario, la recomendación de productos, la optimización de procesos y muchos otros [24]. El proceso de machine learning consta de varias etapas, que incluyen la recopilación y limpieza de los datos, la selección del modelo adecuado, la alimentación de los datos al modelo, el ajuste y entrenamiento del modelo y la evaluación y optimización del rendimiento del modelo.

Unos de los usos más destacados en donde se utilizan algoritmos de aprendizaje automático son los sistemas de alerta de tráfico como Google Maps, redes sociales como Facebook, Instagram o X (Twitter), servicios de transporte y desplazamientos como Uber, sistemas de recomendación de productos, sistemas de asistente personal virtual, vehículos autónomos y traductores como Google [25].

Tecnologías

Para desarrollar esta investigación se hará uso de las siguientes tecnologías.

Python: Es un lenguaje programación de alto nivel que se utiliza para el desarrollo de una amplia gama de aplicaciones. Actualmente es el lenguaje que mejor documentación y librerías ofrece para el desarrollo e implementación de modelos predictivos.

Google Colaboraty: es un entorno online producto de Google, que permite la escritura y ejecución de código escrito en el lenguaje Python, se especializa en el desarrollo de tareas y aplicaciones de aprendizaje automático y análisis de datos.

GRIDSEARCH

Es una técnica de validación cruzada que viene incluida en el paquete de scikit learn [26]. Esta herramienta permite entrenar modelos computacionales a través de diferentes parámetros para así hallar la combinación adecuada que permita dar como resultado un mayor grado de efectividad de los modelos.

De acuerdo con [27] la estructura y parametrización de GridsearchCV es la siguiente.

```
class sklearn.model_selection.GridSearchCV(estimator, param_grid, *, scoring=None, n_jobs=None, refit=True, cv=None, verbose=0, pre_dispatch='2*n_jobs', error_score=nan, return_train_score=False)
```

estimator: Hace referencia al modelo que se entrenará, en este caso un **Random Forest**.

param_grid: Es un diccionario con los nombres de parámetros (str) como claves y listas de configuraciones de parámetros para probar como valores, son los parámetros del modelo que se entrenará.

cv: Determina la estrategia de división de validación cruzada. Las posibles entradas para cv son:

- Ninguno, para utilizar la validación cruzada quíntuple predeterminada.
- entero, para especificar el número de pliegues.
- divisor CV
- Un rendimiento iterable (entrenamiento, prueba) se divide en matrices de índices.

n_jobs: Número de trabajos que se ejecutarán en paralelo. None significa 1 y -1 significa utilizar todos los procesadores.

Información tomada de [27]

Modelos De Clasificación

Un modelo de clasificación es un método utilizado para identificar a qué categoría o clase pertenece un determinado conjunto de datos. La clasificación es un tipo de análisis predictivo en el que se utilizan algoritmos de aprendizaje automático para predecir la categoría o clase de nuevos datos basándose en los patrones identificados en los datos de entrenamiento previamente etiquetados [28].

Para construir un modelo de clasificación, se utiliza un conjunto de datos de entrenamiento que contiene datos con etiquetas. El algoritmo de aprendizaje automático examina los datos de entrenamiento y busca patrones que puedan utilizarse para predecir la categoría o clase de nuevos datos [10]. Una vez que se ha construido el modelo de clasificación, se puede utilizar para predecir la categoría o clase de nuevos datos desconocidos.

Los modelos de clasificación se utilizan en una amplia variedad de aplicaciones, como la detección de spam en correos electrónicos, la detección de fraudes en transacciones financieras, la identificación de enfermedades en diagnósticos médicos, la clasificación de imágenes y la detección de anomalías en sistemas de seguridad. Existen varios modelos de clasificación, pero los que se implementaran en esta investigación son:

Árboles de Decisión

Un modelo de clasificación no lineal que divide el conjunto de datos en subconjuntos más pequeños por medio de respuestas binarias, verdadero o falso, las cuales surgen como respuesta a preguntas que descienden de una pregunta objetivo, la cual es la que da el parámetro final para permitir clasificar un conjunto de datos [29].

Random Forest

El algoritmo está compuesto de un conjunto de árboles de decisión en donde cada árbol del conjunto se compone de una muestra de datos extraída de un conjunto de entrenamiento con reemplazo, llamada muestra de arranque. La muestra se divide en un 70% y 30%, en donde el 30% se usa como datos de prueba [6]. El algoritmo de Random Forest tiene 3 parámetros claves:

- Tamaño del nodo
- Cantidad de árboles
- Cantidad de características muestreadas

Los grandes beneficios de este algoritmo es que ofrece un bajo riesgos al sobre ajuste, caso contrario al uso de un solo árbol de decisión, y también ofrece un alto grado de predicción. “Mientras que los árboles de decisión consideran todas las posibles divisiones de características, los bosques aleatorios solo seleccionan un subconjunto de esas características” [30].

De acuerdo con [31] la estructura y parametrización de modelo de un Random Forest es la siguiente.

```
name.RandomForestClassifier(n_estimators=100, *, criterion='gini', max_depth=None, min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='sqrt', max_leaf_nodes=None, min_impurity_decrease=0.0, bootstrap=True, oob_score=False, n_jobs=None, random_state=None, verbose=0, warm_start=False, class_weight=None, ccp_alpha=0.0, max_samples=None, monotonic_cst=None)
```

Descripción de parámetros:

criterion: Hace referencia a las funciones que son admitidas para medir la calidad de las divisiones. Cuenta con 3 funciones, la función por default es **gini** y las otras 2 son entropía y log_loss.

max_depth: Es la máxima profundidad que tendrá el árbol, por default se establece como **None** esto significa que no se generan nuevos nodos hasta que todas las hojas sean puras o el número de hojas sea menor a min_samples_split.

min_samples_split: Hace referencia al mínimo de muestras para dividir un nodo, por default viene configurado en **2**.

min_samples_leaf: Número de muestras que pueden estar presentes en un nodo hoja, por default viene configurado en **1**, Esto significa que el árbol se dividirá de a una condición (columna).

max_features: Es la cantidad de características que se consideran al buscar la mejor división, por default es **sqrt** pero también se puede usar log2 o None.

Esta información fue tomada de [31].

Ji-Cuadrado

La prueba ji-cuadrado es un procedimiento estadístico utilizado para contrastar hipótesis de independencia de variables categóricas [32], concretamente permite definir si existe algún grado de asociación entre diversas variables en un mismo estudio [33].

Para hacer uso de esta prueba primero se tiene que planear una hipótesis nula y una alterna, y se juzgan bajo un nivel de significancia α y el criterio se toma a través del valor p. En general los niveles de significancia más utilizados son del 1%, 5% o 10%. Para el procedimiento de la prueba se utiliza el estadístico X_o^2 dado por la fórmula:

$$X_o^2 = \sum_{i=1}^f \sum_{j=1}^c \frac{(n_{ij} - E_{ij})^2}{E_{ij}}$$

Matriz de Confusión

La matriz de confusión es una herramienta de evaluación utilizada en el aprendizaje automático y otras disciplinas relacionadas para evaluar el rendimiento de un modelo de clasificación, la cual resume el número de predicciones correctas e incorrectas realizadas por un modelo en un conjunto de datos de prueba. La tabla suele tener cuatro entradas: verdaderos positivos (VP), verdaderos negativos (VN), falsos positivos (FP) y falsos negativos (FN) [34].

Verdaderos positivos (VP): se refiere al número de casos positivos que fueron correctamente identificados como positivos por el modelo.

Verdaderos negativos (VN): se refiere al número de casos negativos que fueron correctamente identificados como negativos por el modelo.

Falsos positivos (FP): se refiere al número de casos negativos que fueron incorrectamente identificados como positivos por el modelo.

Falsos negativos (FN): se refiere al número de casos positivos que fueron incorrectamente identificados como negativos por el modelo.

Permite a los usuarios evaluar la precisión, sensibilidad, especificidad y otras medidas de rendimiento del modelo de clasificación. A partir de la matriz de confusión, también se pueden calcular la tasa de error, la tasa de verdaderos positivos, la tasa de falsos positivos, la tasa de verdaderos negativos y la tasa de falsos negativos [34].

Métricas De Evaluación

Existen varias métricas de evaluación de un modelo de clasificación, cada una de las cuales puede proporcionar información útil sobre el rendimiento del modelo. Algunas de las métricas de evaluación más comunes son:

Exactitud (Accuracy): mide la proporción de predicciones correctas del modelo en relación con el total de predicciones realizadas.

Precisión (Precision): mide la proporción de verdaderos positivos entre el total de casos clasificados como positivos por el modelo.

Sensibilidad o Recall: mide la proporción de verdaderos positivos entre el total de casos positivos en el conjunto de datos.

Especificidad (Specificity): mide la proporción de verdaderos negativos entre el total de casos negativos en el conjunto de datos.

F1-Score: es una medida de la precisión y la sensibilidad del modelo y es útil cuando hay un desequilibrio entre las clases de datos.

Área bajo la curva ROC (AUC-ROC): mide la capacidad del modelo para distinguir entre las clases y se utiliza cuando se desea comparar modelos con diferentes umbrales de clasificación.

Curva ROC: es una representación gráfica de la sensibilidad en función de la tasa de falsos positivos para diferentes umbrales de clasificación.

La elección de la métrica de evaluación depende del objetivo y la naturaleza del problema de clasificación. Por ejemplo, la precisión puede ser más importante en un problema en el que se busca minimizar los falsos positivos, mientras que la sensibilidad puede ser más importante en un problema en el que se busca minimizar los falsos negativos [34].

VII. Metodología

Metodología CRISP

CRISP-DM (Cross Industry Standard Process for Data Mining) proporciona una descripción normalizada del ciclo de vida de un proyecto estándar de análisis de datos, de forma análoga a como se hace en la ingeniería del software con los modelos de ciclo de vida de desarrollo de software [29].

CRISP abarca el análisis de datos como un proyecto profesional, dando un contexto más amplio que enriquece el proceso de elaboración de los modelos. Plantea un ciclo de vida para los proyectos, el cual consiste en seis fases.

Comprensión del negocio: La fase inicial se dedica a comprender de los objetivos y necesidades del proyecto. Luego se transforma este conocimiento a un problema de minería de datos y se realiza un plan preliminar diseñado para alcanzar los objetivos.

Estudio y comprensión de los datos: Es la fase que se enfoca en familiarizarse con los datos, identificar los problemas de calidad, descubrir conocimiento preliminar sobre los datos para formar una hipótesis respecto a la información.

Análisis y preparación de los datos: En esta fase, se preparan y se limpian los de datos para construir el conjunto final de datos que se utilizaran para el entrenamiento del modelo.

Modelado: En esta fase, se aplican las técnicas de modelado que se consideran pertinentes al problema y se calibran los parámetros. Algunas técnicas tienen requerimientos y procesos específicos para el manejo de los datos, por lo tanto, a veces se requiere regresar a la fase de preparación de datos.

Evaluación: Para esta etapa ya se han construido uno o varios modelos que parecen ser óptimos desde una perspectiva de análisis de datos. Antes de proceder a la siguiente etapa es necesario evaluar a fondo y revisar los pasos ejecutados para crearlo, comparar el modelo obtenido con los objetivos del proyecto.

Despliegue: el proceso no finaliza solo con la creación del modelo y obtención de nueva información, es necesario organizar y presentar los resultados para que el cliente pueda usarlos y tomar decisiones que beneficien al negocio.




Fig. 3. Representación gráfica del ciclo de la metodología CRIPS

Nota: Fuente propia.

Etapas de desarrollo:

- Obtener información académica, socioeconómica y relevante de los estudiantes de la UCC sede Villavicencio, para consolidar el conjunto de datos.
- Desarrollar el proceso de extracción, transformación y limpieza del conjunto de datos para mejorar la calidad del conjunto de datos
- Análisis del conjunto de datos para determinar qué información es la necesaria para entrenar el modelo y la que no es vital será eliminada.
- Posteriormente se realizará un proceso de limpieza de datos faltantes y datos atípicos con el objetivo de aumentar la calidad del conjunto de datos.
- Análisis descriptivo del conjunto de datos.
- Se realizará un proceso de transformación de datos categóricos a datos numéricos para poder proceder al proceso de entrenamiento de modelos.
- Sé realizara un estudio detallado sobre los parámetros que requiere cada modelo según su configuración, para determinar cuáles son las condiciones del conjunto de datos que permita explotar al máximo el potencial de predicción de cada variante del modelo.
- Sé realizara la carga de datos para su respectivo entrenamiento.
- Verificar los resultados obtenidos de los modelos computacionales.

- Luego de obtener los resultados de cada modelo, se aplicarán las métricas de evaluación correspondientes para determinar si los modelos se encuentran dentro de los parámetros de evaluación.
- Si alguno de los modelos no cumple con los requerimientos básicos, se tendrá que revisar el proceso de limpieza y selección, luego se volverá a entrenar dicho modelo hasta obtener los resultados esperados.
- Por ultimo los modelos se evaluarán entre sí por medio de la matriz de confusión, en base a esta comparación se realizarán las conclusiones finales.

VIII. Desarrollo del trabajo

IX. Fase de recolección de datos.

Para la recolección de datos se construyó una encuesta en Google Forms la cual va dirigida únicamente a estudiantes de la UCCV, en donde se redactaron más de 50 preguntas que se dividen en 4 secciones:

- 1) Autorización y política de tratamiento de datos personales
- 2) Datos académicos e información personal: En esta sección se realizan preguntas de carácter personal como correo institucional, ID universitario, correo, edad, carrera, semestre actual. etc.
- 3) Información familiar y financiación: En esta sección se realizan preguntas sobre el núcleo familiar, datos demográficos, estado civil, ingresos mensuales, financiación del semestre, autoidentificación respecto a su programa académico, etc.
- 4) Percepción: En esta sección se realizan preguntas de evaluación de 1 al 10 sobre la opinión de los estudiantes respecto a aspectos claves de la universidad, tales como la el método de calificación, pedagogía de los docentes, motivación para culminar sus estudios, costo del semestre, etc.

Esta encuesta se dividió en 2 periodos de tiempo durante el año 2023, los periodos de tiempo son de 2 semestres, los cuales corresponden a los ciclos académicos 2023-10 (el cual llamaremos DD2310 de aquí en adelante) y 2023-20 (el cual llamaremos DD2320 de aquí en adelante). Esta encuesta tuvo una corrección para el periodo D2320 ya que se observó que había errores de redacción y de comprensión en la formulación de algunas preguntas, también se encontraron preguntas ambiguas que no generaban información relevante para la investigación y por último se agregaron preguntas ramificadas, en donde según la respuesta se abría campo a nuevas preguntas, por lo tanto, fue necesario realizar un proceso de análisis y ajuste para poder unificar las 2 encuestas.

X. Fase de análisis y unificación de los 2 datasets (Estudio y compresión de los datos).

Luego de haber extraído la información de la encuesta de Google Forms en formato XMLS, se realizó una identificación y caracterización de las columnas (preguntas) para posteriormente hallar una solución a la unificación de ambos datasets. Esta caracterización se plasmó en las siguientes tablas.

En la tabla 2 se identificó cada columna por su nombre original, posteriormente se le asignó un seudónimo y una breve descripción.

La siguiente tabla sirve como apoyo para identificar las abreviaturas en la tabla 2.

TABLA I
ABREVIATURA DE DATOS DE INFORMACIÓN

TD	Tipo de dato
NC	Numérico
NM	Nominal
B	Binario

TABLA II
DESCRIPCIÓN DE LOS DATOS DE LA ENCUESTA

Título original	Seudónimo	Descripción	TD
HASH	HASH	ID de identificación anónimo para los estudiantes que respondieron ambas encuestas	NC
Programa académico	carrera	Programa académico al que pertenece el estudiante	NM
Promedio académico	promedio_acad	promedio académico acumulado del estudiante	NC
Edad (Años)	edad	Edad del estudiante	NC
¿Sisbén?	sisben	Tipo o nivel de seguro de salud público del estudiante	NM
Método de transporte más frecuente para ir a la universidad	transporte	Medio de transporte que usa el estudiante	NM
Semestre actual	semestre	Semestre actual en el que se encuentra el estudiante	NM
¿Usted recibió orientación vocacional acerca de la carrera profesional para ingresar a la universidad por primera vez?	o_voca	¿El estudiante tuvo algún tipo de orientación al momento de elegir la carrera académica?	NM
¿Elegió la carrera principalmente por?	e_carrera	Razón por la cual el estudiante seleccionó su carrera actual	NM
Al iniciar la carrera ¿Usted tenía una idea precisa sobre el tipo de estudios que quería realizar?	i_carrera	¿El estudiante tenía algún conocimiento previo sobre su carrera?	NM
En qué nivel se identifica con el perfil requerido para su carrera	autopercpcion	¿Cómo se siente identificado el estudiante con su carrera?	NM
¿Ha abandonado o interrumpido de manera temporal sus estudios de pregrado?	aban_inter	¿El estudiante anteriormente ha abandonado o interrumpido sus estudios?	B
¿Cuál fue la razón?	Razón	Razón por la cual desarto o abandono sus estudios	NM

En semestres anteriores ¿ha pensado en dejar o retirarse de la carrera?	p_desertar	¿El estudiante ha pensado en desertar o abandonar sus estudios?	B
¿Cuáles serían las razones en ese momento?	razones	En este campo se pregunta la razón por la cual ha pensado en desertar o abandonar sus estudios	NM
En caso de haber sido trasladado de otra universidad considera que la decisión afectó su futuro	c_universidad	El estudiante anteriormente ha realizado un cambio de universidad	NM
Durante el último año académico señale si ha vivido alguna de las experiencias siguientes.	e_negativas	El estudiante ha vivido alguna experiencia de alto impacto en su vida	NM
¿En qué grado considera que le afectó (afectaron)? Donde 2 es más bajo y 10 más alto en afectación.	g_afectacion	Grado de afectación de estas experiencias	NC
Con relación a la carrera que estudia actualmente usted ha pensado	r_carrera	¿El estudiante ha pensado en tomar alguna decisión académica respecto a sus estudios?	NM
¿Su trabajo afecta sus estudios?	t_estudios	El estudiante considera que el trabajo afecta su desempeño académico	NM
¿Cuál es su rango de ingresos mensuales? (Obtenidos de su propio trabajo)	ingresos	Rango de ingresos mensuales del estudiante	NM
¿Usted nació en el Departamento del Meta?	n_dep	El estudiante nació en el departamento del Meta	B
¿En qué municipio reside usted actualmente?	m_residencia	En cual municipio del departamento del meta vive actualmente	NM
Personas que dependen económicamente de usted:	p_cargo	El estudiante es responsable económicamente de otras personas	NM
Método de financiación de sus estudios (puede marcar más de una respuesta)	financiacion	Medio de pago de sus estudios	NM
¿Usted tiene hijos?	t_hijos	El estudiante tiene hijos	B
¿Considera que el embarazo es una causa de deserción estudiantil en la universidad?	embarazo_des	¿El estudiante considera que el embarazo es una causa de deserción?	NM
¿Con qué frecuencia ha experimentado dificultades para gestionar el tiempo para sus estudios?	dificultades_t	Frecuencia que tiene el estudiante para gestionar el tiempo de sus estudios	NM
¿Qué tanto considera que puede afectar la falta de apoyo familiar en la decisión de abandonar la universidad?	a_familiar	El estudiante considera que la falta de apoyo familiar es una causa para la deserción	NM
A usted en términos general ¿en qué concepto lo tiene su familia como estudiante?	c_familiar	Concepto académico que tiene la familia sobre el estudiante	NM
Bajo su concepto ¿qué efecto tiene el estrés académico en la deserción universitaria?	e_acad	El estudiante si considera que el estrés académico es una causa de deserción	NM
¿Con qué frecuencia ha experimentado dificultades académicas que le han hecho considerar la posibilidad de desertar?	d_acad	Frecuencia con la que el estudiante ha tenido dificultades académicas que lo lleven a pensar desertar	NM
En promedio ¿Cuántas horas dedica a sus estudios a la semana sin contar	h_semanal	En este campo se pregunta cuantas horas de estudio a la semana dedica el estudiante	NM

las horas de clase (trabajo independiente)?			
Respecto al apoyo que sus profesores le brindan dentro y fuera del aula de clases en su proceso de formación ¿usted considera que?	a_profesores	Disposición de los profesores a brindar apoyo a los estudiantes	NM
¿Usted cree que la calidad de los profesores y la calidad de sus clases influyen en la deserción estudiantil?	c_profesores	¿Los estudiantes consideran que la calidad de los profesores influye en la deserción?	NM
Grado de conformidad con el método de calificación actual	m_calificacion	Grado de conformidad con el método de calificación	NC
Pedagogía de los docentes	p_profesores	Nivel de pedagogía consideran que tiene de los profesores	NC
Perfil académico requerido y competente de los docentes	per_profesores	¿Los estudiantes consideran que el nivel académico de los profesores es adecuado?	NC
Motivación por culminar sus estudios profesionales	motivacion	Nivel de motivación que tienen los estudiantes para culminar sus estudios	NC
¿Qué tanto cree que afecta el acoso sexual o psicológico por parte de los profesores, compañeros y demás personal académico en la decisión de abandonar los estudios?	acoso_psc	¿El acoso sexual o psicológico influye en la deserción?	NC
Carga académica suficiente. Seleccione menos de 5 si deberían poner menos trabajos, 5 si está bien, más de 5 y hasta 10 si siente que deberían exigir más.	c_acad	¿El estudiante consideran que la carga académica de la universidad es adecuada?	NC
Valor del semestre reflejado en la calidad educativa	v_semestre	¿El valor del semestre reflejado en la calidad educativa?	NC
Fortalecimiento y competencias de habilidades prácticas y aplicables	habilidades_pa	¿El estudiante considera que ha mejorado sus habilidades prácticas y aplicables?	NC
Tu nivel de adaptación al entorno universitario	adaptacion_u	Nivel de adaptación al entorno universitario	NC
Facilidad de uso del Campus Virtual	campus	Facilidad del uso del campus virtual de la universidad	NC
Recomendación de la universidad a otras personas	recomendacion_u	Probabilidad de que el estudiante recomiende a la universidad	NC

Posteriormente en la tabla III se muestra un análisis descriptivo de cada columna incluyendo las ramificaciones que algunas incluían.

TABLA III
ANÁLISIS DESCRIPTIVO DE LAS PREGUNTAS DE CARÁCTER UNIVERSITARIO

Atributo	Repuesta	Ramificación	Respuesta
carrera	- I Sistemas	f_Ingreso_s	- Antes de 2024 A - A partir de 2024 A
	- I. Civil	1f_Ingreso_c	- Antes de 2022 B - A partir de 2022 B
	- Medicina - Odontología - Enfermería ⁴ - MVZ - Contaduría - Psicología - Derecho -A. Empresas		
promedio_acad	(1 5)		
edad	(15 80)		
sisben	- A1 <= A5 - B1 <= B7 - C1 <= C18 - D1 <= D21		
transporte	- Moto - Carro - S. Público - Bicicleta - A pie - Otro		
semestre Tipo de dato: Nominal	(1)	o_voca	- Colegio - Universidad - Profesional - B. Propia - Padres o familia - Ninguna
		e_carrera	- Vocación o gusto - Facilidad de mercado laboral - Tradición familiar - Interés por disciplina de estudio - Padres - Pareja y/o amigos - Otro
		i_carrera	- Sí - Indeciso entre varias opciones - No tenía idea de que estudiar - No quería estudiar
	(2 3 4 5 6 7 8 9 10)		

autopercepcion	- Totalmente - Mucho - Muy poco - Nada		
-----------------------	---	--	--

TABLA IV
ANÁLISIS DESCRIPTIVO DE LAS PREGUNTAS DE CARÁCTER UNIVERSITARIO, SEGUNDA PARTE

Atributo	Repuesta	Ramificación	Respuesta	Ramificación	Respuesta
aban_inter	- Sí	razon	- Dificultades académicas - Problemas financieros - Falta de interés por la carrera - Problemas personales o familiares - Problemas de salud mental - Falta de apoyo u orientación U. - Falta de motivación		
	- No	p_desertar	- Sí	Razones	- Dificultades económicas - Ubicación laboral - Cambio de ciudad - Aplazamiento de semestre - Dificultades familiares o personales - Bajo rendimiento académico - Falta de interés - Enfermedad - Otro
			- No		
c_universidad	- Negativamente - No afectó - Positivamente - No sé aún - No aplica				
e_negativas	- Fallecimiento de un padre - Separación de padres - Ser madre o padre - Problemas psicológicos - Ingresar al mundo laboral - Pérdida de trabajo - Otros eventos - Ninguna				
g_afectacion	(1 2 3 4 5 6 7 8 9 10)				

r_carrera	- Cancelar una materia o más - Cancelar semestre - Cambiarse de carrera - Retirarse definitivamente - Ninguno				
------------------	---	--	--	--	--

TABLA V

ANÁLISIS DESCRIPTIVO DE LAS PREGUNTAS DE CARÁCTER PERSONAL, FAMILIAR Y FINANCIACIÓN.

Atributo	Repuesta	Ramificación 1	Valor
t_estudios	- No trabajo - Me afecta bastante (-) -Me afecta poco (-) - No me afecta - Me afecta poco (+) - Me afecta bastante (+)		
ingresos	- No trabajo - Hasta \$1.160.000 - \$1.160.001 - \$ 2.320.000 - \$2.320.001 - \$3.480.000 - \$3.480.001 - \$4.640.000 - Más de \$4.640.001		
nac_dep	- Si - No		
m_residencia	- Acacías - Barranca de Upía - Cabuyaro - Castilla la nueva - Cubarral - Cumaral - El Calvario - El Castillo - El Dorado - Fuente de Oro - Granada - Guamal - La Macarena - La Uribe - Lejanías - Mapiripán - Mesetas - Puerto Concordia - Puerto Gaitán - Puerto López - Puerto Rico - Restrepo - San Carlos de Guaroa - San Juan de Arama - San Juanito		

	- San Martín - Villavicencio - Vista Hermosa - Otro		
p_cargo	- Ninguna - Pareja - Padres - Hermanos - Hijos		
financiacion	- Padres o familia - Crédito - Beca - Trabajo propio		
t_hijos	- Si	2.8) embarazo_des Tipo de dato: Nominal	- Nada probable - Poco probable - Muy probable - Altamente probable
	- No		
dificultades_t	- Nunca - Pocas veces - Muchas veces - Siempre		
a_familiar	- Nada - Relativamente poco - Mucho - Demasiado		
c_familiar	- Pésimo estudiante - Mal estudiante - Buen estudiante - Muy buen estudiante		
e_acad	- Ninguno - Muy poco efecto - Mucho - Demasiado		
d_acad	- Nunca - Pocas veces - Muchas veces - Siempre		
h_semanal	- Entre cero y dos - Entre dos y cuatro - Entre cuatro y seis - Entre seis y ocho - Entre ocho y diez - Entre diez y doce - Más de doce		
a_profesores	- Siempre dispuestos a ayudar - A veces dispuestos a ayudar - Rara vez dispuestos a ayudar - Nunca dispuesto a ayudar		
c_profesores	- Sí, definitivamente - En cierta medida - No, no influye		

	- No estoy seguro/a		
--	---------------------	--	--

TABLA VI
ANÁLISIS DESCRIPTIVO DE LAS PREGUNTAS DE CARÁCTER DATOS DE PERCEPCIÓN.

Atributo	Valor
m_calificacion	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
p_profesores	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
per_profesores	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
motivacion	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
acoso_psc	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
c_acad	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
v_semestre	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
habilidades_pa	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
adaptacion_u	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
Campus	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)
recomendacion_u	(1, 2, 3, 4, 5, 6, 7, 8, 9, 10)

XI. Fase de análisis, limpieza y ordenamiento de los datos.

En esta sección se realizó un análisis detallado de los conflictos presentes entre los 2 datasets que se presentaban al momento de realizar una unión entre estos. Debido a que existen variaciones entre los datasets D2310 y D2320 fue necesario analizar al detalle cada uno de las diferencias que existían entre estos 2, los principales casos que se encontraron fueron los siguientes:

- 1) De escritura: Existen varios casos en donde hay diferencias en la escritura de las respuestas de cada columna, como es el caso de la columna **carrera** en donde en D2320 las opciones de respuesta se almacenaban como **Ing. Sistemas** y en D2310 se almacenaban como **Ing Sistemas**, si el punto de abreviación, entonces al momento de combinar los datos se creaban 2 nuevos registros para un total de 4, este es un caso sencillo, pero, así mismo como este existen más casos en donde las respuestas eran sinónimos entre sí, para dar solución a este caso se optó por realizar una corrección de escritura directamente desde Excel.
- 2) De tipo de dato: Se hallaron unos casos en donde en D2310 hay registros de tipo nominal y en D2310 de tipo numérico y además en donde hay registros numéricos individuales en un data set y en el otro son un rango numérico el cual por defecto era tomado como un dato nominal, como es el caso de la columna **promedio_acad** en donde en D2310 los registros se almacenan como **3.0-3.3**, **3.4-3.6**, estos datos son tomados como tipo nominal y en D2320 los registros se almacenan de manera individual **3.0**, **3.1**, **3.2**, **3.3**. por lo tanto, se almacenan como datos numéricos, por lo tanto, fue necesario realizar una asignación aleatoria utilizando la distribución en base a la variable numérica con el fin de hallar cada valor individual. El proceso se desarrolló de la siguiente manera.

Promedio académico 2320			Promedio académico 2310		Promedio académico modificado		
Rango:	3.0 - 3.3		Rango:	3.0 - 3.3	Rango:	3.0 - 3.3	
3	16	69,57%	Total	22	3	15,3	15
3,1	0	0,00%			3,1	0	0
3,2	5	21,74%			3,2	4,8	5
3,3	2	8,70%			3,3	1,9	2
Total	23	100,00%			Total	22	22

Fig. 4. Análisis estadístico

Primero se obtuvo la varianza de los datos numéricos entre el rango 3 y 3.3 de D2320 (23 registros) y posteriormente se calculó el porcentaje de cada registro en el rango, de igual modo se obtuvo el total de datos de este mismo rango en D2310 (22 registros) y posteriormente se halló la proporción para estos registros. En la figura 3 se puede observar que la proporción es similar, solo un registro de diferencia, por lo tanto, al finalizar el proceso se observa que los nuevos datos para de D2310 es muy similar a D2320.

Luego de obtener estos resultados se realizó un script en Python en donde se transformaron los datos de D2310 según la nueva distribución.

Este mismo método se aplicó para los demás casos, los cuales se pueden observar en la sección de **Anexos**.

- 3) Eliminación de registros: En algunos casos fue necesario eliminar registros ya que en D2320 se agregó la opción de preguntas ramificadas las cuales solo podían ser contestas en función de una respuesta anterior, esto generó que en ciertas columnas hubiera menos registros que en D2310, como lo fue en el caso de **e_carrera**, que en D2320 se preguntaba solo a los estudiantes de primer semestre en donde de 203 registros solo 8 estudiantes pertenecían a ese semestre, por lo tanto, se optó por eliminar los registros de los estudiantes que no pertenecían al primer semestre de D2310.

En esta sección se muestran unos casos específicos, la información completa la puede consultar en la sección de **Anexos**.

Tratamiento de respuestas múltiples

Después de obtener un método para unir los datasets D2310 y D2320 de una forma uniforme y limpia, se procede a resolver las columnas con respuestas múltiples, implementando un código en Python el cual una separación por columnas con las respuestas principales y luego en ellas se ingresa la información de las respuestas de forma binaria basado en Dommies, ejemplo:

Tomaremos de ejemplo la columna **p_cargo**, en donde se pregunta si el estudiante es responsable económicamente de alguna otra persona, las opciones de respuesta son

- Hermanos
- Hijos
- Pareja
- Padres
- Ninguno

Supongamos que existe un registro con respuesta múltiples:

- Hermanos; Padres; Pareja
- Hijos; Pareja
- Ninguno

Para este caso la solución es:

TABLA VII
EXPLICACIÓN GRÁFICA DE LA APLICACIÓN DE DOMMIES.

#registro	Hermanos	Hijos	Pareja	Padres	Ninguno
1	1	0	1	1	0
2	0	1	1	0	0
3	0	0	0	0	1

De esta forma se asignan valores booleanos en donde las respuestas únicas existentes en la respuesta múltiple serán marcadas con un 1 y las que no hacen parte de esta serán marcadas con un 0.

El resultado final de forma organizada se puede apreciar en la Tabla VIII.

TABLA VIII
APLICACIÓN DE LA METODOLOGÍA DUMMIES.

Nombre de la columna: p_cargo	
p_1	Hermanos
p_2	Hijos
p_3	Ninguna
p_4	Padres
p_5	Pareja

En esta sección se muestran unos casos específicos, la información completa la puede consultar en la sección de **Anexos**.

Transformación de datos categóricos a numéricos.

Después de realizar el tratamiento de respuestas múltiples se procede a hacer la transformación de datos categóricos a numéricos con el fin de preparar los datos para la parametrización y entrenamiento del modelo Random Forest.

En la tabla VIII se explica cómo funciona el método de transformación.

TABLA IX
 REPRESENTACIÓN GRÁFICA DE LA TRANSFORMACIÓN DE DATOS CATEGÓRICOS A NUMÉRICOS.

Nombre de la columna: transporte	
A pie	0
Bicicleta	1
Carro	2
Moto	3
Otro	4
Servicio público	5

En la sección de **Anexos** puede consultar la información completa.

XII. Análisis exploratorio de datos y correlaciones

Gráficas para el entendimiento del conjunto de datos.




Fig. 5. Cantidad de estudiantes por carrera

Nota: Fuente propia.




Fig. 6. Auto percepción de los estudiantes respecto a su carrera




Fig. 7. ¿Los estudiantes en algún momento han abandonado o interrumpido sus estudios?




Fig. 8. ¿Tiene hijos?

Estas gráficas de pastel brindan una percepción más clara de la estructura de la encuesta, en la figura 5 se puede observar que existe mayor cantidad de estudiantes de la carrera de Ingeniería Civil. En la figura 7 se puede observar que una cantidad considerable de estudiantes en algún momento de su ciclo académico han interrumpido o abandonado sus estudios académicos.

Se seleccionaron 4 semestres en específico, los cuales tenían un comportamiento más interesante, el semestre 2, 4, 6 y 10.




Fig. 9. Gráfico de bigotes vs promedio académico.

Gráfico de barras de la motivación de los estudiantes vs el promedio académico.

Se realizó una agrupación de distintos niveles de motivación.

- Personas con grado de motivación inferior a 5.
- Personas con grado de motivación de 6 y 7.
- Personas con grado de motivación igual a 8
- Personas con grado de motivación igual a 9
- Personas con grado de motivación igual a 10
- Todos los registros $1 < x < 10$









Fig. 10. Gráfico de barras de la motivación de los estudiantes en función si tiene o no hijos.




Fig. 11. Mapa de calor semestre vs motivación.

Mapa de calor semestre vs método de calificación (m_calificacion), pedagogía de los profesores (p_profesores), perfil académico de los profesores (per_profesores), motivación (motivacion), carga académica (c_acad), valor del semestre (v_semestre), habilidades prácticas (habilidades_pa), adaptación a la universidad (adaptacion_u), recomendación de la universidad (recomendacion_u).




Fig. 12. Mapa de calor semestre vs 9 variables

En la figura 11 se puede ver de manera amplia la agrupación de datos de la motivación de los estudiantes según el semestre por medio de un mapa de calor, en donde según se indica en la barra derecha, entre mayor concentración de respuestas se marca el valor con un color rojo y si hay ausencia de respuestas se marca con un color azul opaco, por lo tanto, se puede observar que existe una gran concentración de datos a partir del grado de motivación 8, lo cual al sumar los valores de las columnas 8, 9 y 10 se obtiene un valor de 337 datos que representan un 69.8% de datos del conjunto en total, por lo tanto, se puede inferir que más del 69% de los estudiantes encuestados tienen la intención de culminar sus estudios académicos.

En la figura 12 se puede observar un mapa de calor en donde se agrupa el promedio de 9 variables de percepción vs el semestre de los estudiantes. Como se mencionó anteriormente en la figura 11, los estudiantes tienen una tendencia positiva a querer finalizar sus estudios, pero, también se puede observar un inconformismo en el método de calificación en donde su puntuación más alta es en los estudiantes de tercer semestre con un valor de 6.2, también se puede observar que en las variables de pedagogía de los profesores (**p_profesores**), perfil profesional de los profesores (**per_profesores**), y habilidades prácticas (**habilidades_pa**) existe una tendencia de disminución conforme avanzan los semestres, siendo el caso más extremo el de habilidades prácticas en donde disminuye 15 puntos del primer semestre al décimo.

Pruebas estadísticas de asociación

Para identificar el grado de asociación entre variables se usó la Prueba ji-cuadrado, la cual nos permite conocer si 2 variables se encuentran relacionadas entre sí, con el fin de poder identificar aquellas que sean de mayor relevancia para este caso de estudio. Se trabajaron las siguientes relaciones:

- El grado de motivación por terminar los estudios (motivacion) vs semestre (semestre), pedagogía de los profesores (p_profesores), afectación del trabajo en el estudio (t_estudio), método de calificación (m_calificacion) y habilidades prácticas (habilidades_pa).
- Pedagogía de los profesores vs valor semestre

En donde para cada caso se usó un nivel de significancia del 10% ($\alpha = 0.1$) por lo tanto el nivel de criterio se define como:

Si el p-valor es menor que α , entonces se rechaza la hipótesis nula.

Teniendo esto en cuenta se plantearon las siguientes hipótesis.

1) El grado de motivación por terminar los estudios (motivacion) vs semestre (semestre)

- H_0 : El grado de motivación por terminar los estudios es independiente del semestre que se esté cursando.
- H_1 : Las dos variables involucradas tienen algún grado de asociación.

TABLA X

motivacion vs semestre		
Valor de p	Valor de α	Relación
0.3126	0.1	$p > \alpha$
Por lo tanto:	No se rechaza la hipótesis nula (H_0)	

Conclusión: las variables motivacion y semestre son variables **independientes**

2) El grado de motivación por terminar los estudios (motivacion) vs pedagogía de los profesores (p_profesores)

- H_0 : El grado de motivación por terminar los estudios es independiente de la calificación de la pedagogía de los profesores.
- H : Las dos variables involucradas tienen algún grado de asociación.

TABLA XI

motivacion vs p_profesores		
Valor de p	Valor de α	Relación
0.0000	0.1	$p < \alpha$
Por lo tanto:	Se rechaza la hipótesis nula (H_0)	

Conclusión: las variables motivacion y p_profesores son variables **dependientes**

3) El grado de motivación por terminar los estudios (motivacion) vs afectación del trabajo en el estudio (t_estudio)

- H_0 : El grado de motivación por terminar los estudios es independiente del impacto del trabajo en los estudios académicos.
- H : Las dos variables involucradas tienen algún grado de asociación.

TABLA XII

motivacion vs t_estudios		
Valor de p	Valor de α	Relación
0.0044	0.1	$p < \alpha$
Por lo tanto:	Se rechaza la hipótesis nula (H_0)	

Conclusión: las variables motivacion y t_estudio son variables **dependientes**

4) El grado de motivación por terminar los estudios (motivacion) vs método de calificación (m_calificacion)

- H_0 : El grado de motivación por terminar los estudios es independiente de la puntuación de la metodología de calificación.
- H : Las dos variables involucradas tienen algún grado de asociación.

TABLA XIII

motivacion vs m_calificacion		
Valor de p	Valor de α	Relación
0.0002	0.1	$p < \alpha$
Por lo tanto:	Se rechaza la hipótesis nula (H_0)	

Conclusión: las variables motivacion y m_calificacion son variables **dependientes**

5) El grado de motivación por terminar los estudios (motivacion) vs habilidades prácticas (habilidades_pa)

- H_0 : El grado de motivación por terminar los estudios es independiente del impacto de los estudios a la mejora de las habilidades prácticas.
- H_1 : Las dos variables involucradas tienen algún grado de asociación.

TABLA XIV

motivacion vs habilidades_pa		
Valor de p	Valor de α	Relación
0.0000	0.1	$p < \alpha$
Por lo tanto:	Se rechaza la hipótesis nula (H_0)	

Conclusión: las variables motivacion y habilidades_pa son variables **dependientes**

6) El valor del semestre (v_semestre) vs pedagogía de los profesores (p_profesores)

- H_0 : El grado de motivación por terminar los estudios es independiente del semestre que se esté cursando.
- H_1 : Las dos variables involucradas tienen algún grado de asociación.

TABLA XV

motivacion vs p_profesores		
Valor de p	Valor de α	Relación
0.0000	0.1	$p < \alpha$
Por lo tanto:	Se rechaza la hipótesis nula (H_0)	

Conclusión: las variables v_semestre y p_profesores son variables **dependientes**.

Con estas pruebas de asociación fue posible identificar que las relaciones que existen entre la pregunta objetivo respecto a otras del dataset, en esta investigación solo se estudiaron 6 casos en donde se logró identificar relaciones que a simple vista no parecían posibles, como es el caso de motivación y p_profesores. Las otras relaciones entre variables pueden ser estudiadas en futuros proyectos.

Parametrización de GridsearchCv y Random Forest

En esta fase se realizó el ajuste de parámetros que permitiera obtener un mayor grado de probabilidad o su mejor score. Mediante cambios en los parámetros del modelo Random Forest se puede variar el resultado del score, esta es una tarea algo tediosa ya que es necesario entrenar una gran cantidad de modelos para hallar el más acertado y esto se traduce a una gran cantidad de tiempo empleado. Para dar solución a este problema y reducir el gasto de recursos se usó GridsearchCv, el cual nos permite establecer un rango de parámetros que irán variando en el entrenamiento del modelo computacional, por lo tanto, se obtendrán una cantidad n de modelos según la necesidad del investigador.

Los parámetros que se consideraron para el modelo computacional Random Forest para esta investigación son los siguientes:

- **Criterion:** gini, entropy y log_loss.
- **Max_features:** auto y sqrt.
- **Max_depth:** 1, 20, 40, 60, 80, 100, 120, 140, 160, 180, 200, 220, 240, 260, 280, 300, 320, 340, 360, 380, 400, 420, 440, 460, 480.
- **Min_samples_split:** 1 - 10
- **Min_samples_leaf:** 1 - 10

Posterior mente estos parámetros son almacenados en una lista llamada **param_grid** y se envían junto con los otros parámetros de GridsearchCv, los cuales son:

- **estimator:** rf_Model
- **param_grid:** param_grid.
- **cv:** 5
- **verbose:** 2
- **n_jobs:** 4

Se entrenaron 2 datasets llamados **DF_final_dummies.xlsx** y **DF_final_numerico** con la misma configuración de parámetros y se obtuvieron los siguientes resultados.

TABLA XVI

Resultados de los modelos entrenados		
Dataset	Parametrización	Score
Df_final_numerico	• criterion: entropy • max_depth: 400 • max_features: auto • min_samples_leaf: 2 • min_samples_split: 3	46.4 %
Df_final_dummies	• criterion: gini • max_depth: 420 • max_features: sqrt • min_samples_leaf: 1 • min_samples_split: 2	45.5 %

Visualización de resultados de los modelos

Df_final_numerico.

En la figura 13 y 14 se puede apreciar un gráfico de dispersión de una muestra de los mejores 5 mil modelos entrenados.

Para el caso de la figura 13 se comparan los resultados de los criterios **Gini**, **entropy** y **log_loss** en base a los parámetros de max_depth: 400, max_features: auto, min_samples_leaf: 2 y min_samples_splits: 3.




Fig. 13. Gráfica de los puntajes según el criterio en DF_final_numerico

Nota: Fuente propia.

Df_final_dummies

Para el caso de la figura 14 se comparan los resultados de los criterios **Gini**, **entropy** y **log_loss** en base a los parámetros de max_depth: 420, max_features: sqrt, min_samples_leaf: 1 y min_samples_splits: 2.




Fig. 14. Gráfica de los puntajes según el criterio en DF_final_dummies

Nota: Fuente propia.

A continuación, se presenta la matriz de confusión del modelo entrenado con el dataset Df_final_numerico.




Fig. 15. Matriz de confusión del modelo numérico

Nota: Fuente propia.

En esta gráfica se aprecia el proceso de evaluación del modelo computacional, en donde se

XIII. CONCLUSIONES

1. Mediante la implementación de un modelo Random Forest fue posible identificar la probabilidad de que un estudiante tenga un bajo nivel de motivación por continuar sus estudios académicos, lo cual lo convertiría en un posible desertor. Se logró obtener una parametrización para el modelo construido dando un nivel de asertividad de **46.4%**.
2. Se logró consolidar un dataset **483 registros** de estudiantes activos de la Universidad Cooperativa de Colombia de la Facultad de Ingenierías (Ingeniería Civil y de Sistemas)
3. Gracias al análisis descriptivo se logró identificar que las variables de mayor peso en la motivación de un estudiante para finalizar sus estudios fueron las variables relacionadas con la percepción universitaria tales como:

- m_calificacion: Método de calificación de la universidad
 - p_profesores: Pedagogía de los profesores en sus métodos de enseñanza
 - v_semestre: Relación del valor del semestre según la calidad de la enseñanza
4. Se entrenaron más de **30.000 modelos** del modelo computacional Random Forest por medio de GridsearchCv con 2 datasets diferentes, el primero está compuesto por registro **numéricos ordinales** y el otro por registros en tipo **dummies**, de los cuales se obtuvo que el dataset que brindó una mayor probabilidad de asertividad fue el numérico con un porcentaje de **46.4%**.
 5. Se recomienda complementar las encuestas, realizar preguntas más profundas en el campo de la percepción y optar por la posibilidad de obtener datos más **veracidad** por medio de la **institución educativa**, con esto se podría aumentar considerablemente el porcentaje de predicción de los modelos para analizar y aplicar estrategias que ayuden a **mitigar** la deserción en la institución educativa

XIV. REFERENCIAS

- [1] A. M. Mariano, A. B. De Magalhães Lelis Ferreira, M. R. Santos, M. L. Castilho, and A. C. F. L. C. Bastos, "Decision trees for predicting dropout in Engineering Course students in Brazil," in *Procedia Computer Science*, Elsevier B.V., 2022, pp. 1113–1120. doi: 10.1016/j.procs.2022.11.285.
- [2] María Camila Jiménez, "Abandono universitario tarea en la que Iberoamérica se sigue rajando." Accessed: Apr. 17, 2024. [Online]. Available: <https://periodico.unal.edu.co/articulos/abandono-universitario-tarea-en-la-que-iberoamerica-se-sigue-rajando>
- [3] A. Gonzalez-Nucamendi, J. Noguez, L. Neri, V. Robledo-Rella, and R. M. G. García-Castelán, "Predictive analytics study to determine undergraduate students at risk of dropout," *Front Educ (Lausanne)*, vol. 8, 2023, doi: 10.3389/educ.2023.1244686.
- [4] E. Ministerio, "ESTADÍSTICAS DE DESERCIÓN ESTUDIANTIL, PERMANENCIA Y GRADUACIÓN EN EDUCACIÓN SUPERIOR Universitario Tecnológico Técnico profesional," 2017. [Online]. Available: <https://www.mineduacion.gov.co/sistemasdeinformacion/1735/articles->
- [5] E. Chinkes, "Pronósticos y data mining para la toma de decisiones. pronóstico sobre la deserción de alumnos de una facultad," 2018.
- [6] J. Mesarić and D. Šebalj, "Decision trees for predicting the academic success of students," *Croatian Operational Research Review*, vol. 367, pp. 367–388, 2016, doi: 10.17535/corr.2016.0025.
- [7] Ministerio de Educación Nacional, "Ministerio de educación nacional Subdirección de Desarrollo Sectorial," 2013. [Online]. Available: www.mineduacion.gov.co
- [8] Caracol Radio, "Más de 39.000 estudiantes abandonaron la universidad en Colombia." Accessed: Mar. 18, 2023. [Online]. Available: https://caracol.com.co/programa/2021/11/04/sanamente/1636049871_761122.html
- [9] Sistema para la Prevención de la Deserción de la Educación Superior, "Estadísticas de Deserción - Sistemas información." Accessed: Mar. 18, 2023. [Online]. Available: <https://www.mineduacion.gov.co/sistemasinfo/spadies/Informacion-Institucional/357549:Estadisticas-de-Desercion>
- [10] E. Barreno-Vereau, "Análisis Comparativo de modelos de clasificación en el estudio de la deserción universitaria," *Interfases*, vol. 0, no. 005, p. 45, Feb. 2012, doi: 10.26439/INTERFASES2012.N005.149.

- [11] D. Santín González, “Detección de alumnos de riesgo y medición de la eficiencia de centros escolares mediante redes neuronales,” 1999. [Online]. Available: <http://www.ucm.es/BUCM/cee/doc/9902/9902.htm>
- [12] H. Felizzola Jiménez, Y. Adriana, J. Arias, A. María, C. Pastrana, and F. Villa Pedroza, “Modelo de predicción para la deserción temprana en la facultad de ingeniería de la universidad de la salle,” 2018.
- [13] K. R. Vergaray, “Modelo predictivo para la detección temprana de estudiantes con alto riesgo de deserción académica,” *Innovación y Software*, vol. 2, no. 2, pp. 6–13, Sep. 2021, Accessed: Feb. 25, 2023. [Online]. Available: <https://revistas.ulasalle.edu.pe/innosoft/article/view/40>
- [14] R. I. Castro López, “Aplicación de técnicas de machine learning para el estudio de deserción temprana y egreso oportuno en estudiantes de ingeniería de la facultad de ciencias físicas y matemáticas.” Accessed: Feb. 25, 2023. [Online]. Available: <https://repositorio.uchile.cl/bitstream/handle/2250/178598/Aplicacion-de-tecnicas-de-Machine-Learning-para-el-estudio-de-desercion-temprana-y-egreso-oportuno-en-estudiantes-de-Ingenieria-de-la-Facultad-de-Ciencias%20Fisicas-y-Matematicas.pdf?sequence=1&isAllowed=y>
- [15] A. Jose and C. Garcia, “Modelo para la predicción de la deserción de estudiantes de pregrado, basado en técnicas de minería de datos,” pp. 1–121, 2020.
- [16] H. Y. Ayala Yaguara, M. Valenzuela Sabogal, and A. Espinosa García, “Obtención de un modelo de minería de datos aplicado a la deserción universitaria del programa de Ingeniería de Sistemas de la Universidad de Cundinamarca.” Accessed: Feb. 25, 2023. [Online]. Available: <https://journal.universidadean.edu.co/index.php/Revistao/article/view/2676/2087>
- [17] V. De La Cruz, “diseño de un modelo predictivo basado en machine learning para el control de la deserción de estudiantes en la universidad ricardo palma,” 2019.
- [18] M. L. Avila Pérez, “Modelo De Predicción De Deserción Estudiantil, Apoyado En Tecnologías De Data Mining, En Un Curso De Primera Matrícula De La Escuela ECBTI De La UNAD,” pp. 1–151, 2021.
- [19] J. D. T. D. F. T. Diofanor Acevedo, “Análisis de la Deserción Estudiantil en el Programa Ingeniería de Alimentos de la Universidad de Cartagena durante el Periodo Académico 2009 - 2013,” Cartagena, 2015.
- [20] Antonio Berlanga, “El camino desde la Inteligencia Artificial al Big Data.”
- [21] “Minería de datos: Qué es y por qué es importante | SAS.” Accessed: Feb. 07, 2024. [Online]. Available: https://www.sas.com/es_co/insights/analytics/data-mining.html
- [22] D. S. G. CESAR PEREZ LOPEZ, *Minería de datos. Técnicas y herramientas*, vol. 1. 2007.

- [23] E. M. Rojas, “Machine Learning: análisis de lenguajes de programación y herramientas para desarrollo,” 2020.
- [24] “‘Machine Learning’: definición, tipos y aplicaciones prácticas - Iberdrola.” Accessed: Feb. 07, 2024. [Online]. Available: <https://www.iberdrola.com/innovacion/machine-learning-aprendizaje-automatizado>
- [25] Wiley, *Fundamentals and Methods of Machine and Deep Learning, Algorithms, Tools, and Applications*. 2022.
- [26] Sandra Navarro, “KeepCoding Bootcamps.” Accessed: May 12, 2024. [Online]. Available: <https://keepcoding.io/blog/que-es-gridsearchcv/>
- [27] “sklearn.model_selection.GridSearchCV — scikit-learn 1.4.2 documentation.” Accessed: May 19, 2024. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html
- [28] J. Carlos González Sánchez and M. Javier Peñaloza Pérez, “Identificación y predicción de estudiantes en riesgo de deserción académica por medio de modelos basados en machine learning,” 2021.
- [29] “Conceptos básicos de ayuda de CRISP-DM - Documentación de IBM.” Accessed: Feb. 08, 2024. [Online]. Available: <https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview>
- [30] IBM, “¿Qué es un bosque aleatorio? | IBM.” Accessed: Feb. 07, 2024. [Online]. Available: <https://www.ibm.com/mx-es/topics/random-forest>
- [31] “sklearn.ensemble.RandomForestClassifier — scikit-learn 1.4.2 documentation.” Accessed: May 18, 2024. [Online]. Available: <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- [32] L. G. Díaz Monroy and M. A. Morales Rivera, *Análisis estadístico de datos categóricos*. Universidad Nacional de Colombia, Facultad de Ciencias, Departamento de Estadística, 2009.
- [33] “Prueba de ji cuadrado de bondad de ajuste | Introducción a la estadística | JMP.” Accessed: May 04, 2024. [Online]. Available: https://www.jmp.com/es_co/statistics-knowledge-portal/chi-square-test/chi-square-goodness-of-fit-test.html
- [34] “La matriz de confusión y sus métricas – Inteligencia Artificial –.” Accessed: Feb. 07, 2024. [Online]. Available: <https://www.juanbarrios.com/la-matriz-de-confusion-y-sus-metricas/>

XV. ANEXO

Primera fase. Análisis detallado: En esta sección se realizó un análisis detallado de los conflictos existentes que se presentaban entre los 2 datasets al momento de realizar una unión, además se creó una nueva columna llamada **ID_S**, la cual cumple con la función de identificar a cada registro según el periodo académico en el que se realizó la encuesta (D2310 o D2320). Este proceso busca identificar las problemáticas y dar con una posible solución o descarte de columnas.

ID: 01	Nombre de la columna: ID_S	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se creo esta columna con el objetivo de tener un valor diferencial entre los datasets D2310 y D2320 Dataset D2310: 1 Dataset D2320: 2	-	-

ID: 02	Nombre de la columna: ID	
Número de registros afectados: 0		
Novedad	Problema	Solución
-	-	-

ID: 03	Nombre de la columna: HASH	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se creo esta columna con el objetivo de tener un valor único que identifique a cada estudiante según un dato personal de identificación para posteriormente poder identificar a los estudiantes que respondieron las 2 encuestas	Datos repetidos y únicos	Aplicar un método de identificación de datos repetidos y luego asignar un ID única a cada estudiante que se encuentre en ambas encuestas

ID: 04	Nombre de la columna: carrera	
Número de registros afectados: 483		
Novedad	Problema	Solución
Primero se eliminaron los registros de las otras carreras para dejar solo los datos de los estudiantes de la facultad de ingeniería (Sistemas y Civil) posteriormente se realizó una unión entre los 2 datasets	- En el Dataset D2310 las respuestas estaban escritas de la siguiente manera Ing Sistemas – Ing Civil - En el Dataset D2320 las respuestas están escritas de la siguiente manera Ing. Sistemas – Ing. Civil La diferencia entre los 2 es un punto	Eliminar el punto de las respuestas del Dataset D2320

ID: 05	Nombre de la columna: promedio_acad	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- En el Dataset D2310 las respuestas son en rangos numéricos ejemplo: 3.0 – 3.3, 3.4 – 3.6 - En el Dataset D2320 las respuestas son numéricas individuales ejemplos: 3.0,3.1, 3.2,3.3,3.4	Realizar una asignación aleatoria utilizando la distribución en base a la variable numérica.

ID: 06	Nombre de la columna: edad	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 07	Nombre de la columna: sisben	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- En el Dataset D2310 las respuestas son en rangos ejemplo: A1 – A5 - En el Dataset D2320 las respuestas son individuales ejemplo: A1, A2, A3, A4, A5	Realizar una asignación aleatoria utilizando la distribución en base a la variable numérica.

ID: 08	Nombre de la columna: transporte	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset D2310 una de las respuestas es Recorrido a pie y en el Dataset D2320 la respuesta es A pie	Modificar los registros del Dataset D2310 al estilo del D2320 (A pie)

ID: 09	Nombre de la columna: semestre	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- En el Dataset D2310 las respuestas son en rangos numéricos ejemplo: 1 – 3 - En el Dataset D2320 las respuestas son numéricas individuales ejemplos: 1, 2, 3	Realizar una asignación aleatoria utilizando la distribución en base a la variable numérica.

ID: 10	Nombre de la columna: o_voca	
Número de registros afectados: 190		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- Es una pregunta con posibilidad de respuestas múltiples - En el Dataset D2320 es una pregunta ramificada para los estudiantes de primer semestre. Solo una fracción de los estudiantes la respondieron esto genera 190 registros vacíos	Eliminar los registros del dataset D2310 y conservar solo los registros de los estudiantes del primer semestre

ID: 11	Nombre de la columna: e_carrera	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- Es una pregunta con posibilidad de respuestas múltiples - En el Dataset D2320 es una pregunta ramificada, lo que significa que solo una fracción de los estudiantes la respondieron esto genera 190 registros vacíos	Eliminar los registros del dataset D2310 y conservar solo los registros de los estudiantes del primer semestre y luego se aplicó un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 12	Nombre de la columna: i_carrera	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- Es una pregunta con posibilidad de respuestas múltiples - En el Dataset D2320 es una pregunta ramificada, lo que significa que solo una fracción de los estudiantes la respondieron esto genera 190 registros vacíos	Eliminar los registros del dataset D2310 y conservar solo los registros de los estudiantes del primer semestre y aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 13	Nombre de la columna: autopercepción	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Existen breves diferencias de escritura entre los datasets, ejemplo: D2310: Me identifico muy poco D2320: Muy poco	Corregir la escritura

ID: 14	Nombre de la columna: aban_inter	
Número de registros afectados: 281		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset 2023 esta pregunta es binaria y hace referencia a una sola pregunta en específico en el DatasetD2310 es una pregunta compuesta conjunto a la pregunta #15 (razón) lo cual genera que en si esta pregunta no exista en el Dataset D2310	Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 15	Nombre de la columna: razon	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	- Es una pregunta con posibilidad de respuestas múltiples - En el Dataset D2320 es una pregunta ramificada, lo que significa que solo una fracción de los estudiantes la respondieron esto genera 115 registros vacíos	Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 16	Nombre de la columna: p_desertar	
Número de registros afectados: 281		
Novedad	Problema	Solución
-	Esta pregunta no existe en el Dataset D2310 por lo tanto genera 281 registros vacíos	Eliminar

ID: 17	Nombre de la columna: razones	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Respuestas múltiples	Eliminar

ID: 18	Nombre de la columna: c_universidad	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Existen breves diferencias de escritura entre los datasets ejemplo: D2310: Afectó su futuro de manera (+) D2320: Positivamente	Corregir la escritura

ID: 19	Nombre de la columna: e_negativas	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Respuestas múltiples	Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 20	Nombre de la columna: g_afectacion	
Número de registros afectados: 281		
Novedad	Novedad	Solución
-	Esta pregunta no existe en el Dataset D2310, por lo tanto, genera 281 registros vacíos	Realizar una asignación utilizando la tendencia central de la relación entre las respuestas de e_negativa y g_afectacion

ID: 21	Nombre de la columna: r_carrera	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Respuestas múltiples	Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 22	Nombre de la columna: t_estudios	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Existen breves diferencias de escritura entre los datasets ejemplo: D2310: Me afecta bastante de manera negativa (-) D2320: Me afecta bastante de manera negativa	Corrección de escritura

ID: 23	Nombre de la columna: ingresos	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Error de escritura	Corregir la escritura

ID: 24	Nombre de la columna: n_dep	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset D2320 esta pregunta es binaria y hace referencia a una sola pregunta en específico en el DatasetD2310 esta pregunta hace referencia a que si el estudiante nació en el departamento del Meta que señale el municipio de nacimiento. Esta es una pregunta que se relaciona con la pregunta #25 (m_residencia)	Eliminar

ID: 25	Nombre de la columna: m_residencia	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	No sé

ID: 26	Nombre de la columna: En caso de ser foráneo ¿En qué municipio del departamento del meta nació?	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se creo esta columna nueva para el Dataset D2320	Esta pregunta no existe en el Dataset D2320	Eliminarla

ID: 27	Nombre de la columna: p_cargo	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset del D2320 es una pregunta se opción múltiple y en D2310 no lo que genera que las respuestas originales se dupliquen y hallan otras con más de una opción	Corregir los errores de las respuestas duplicadas y Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 28	Nombre de la columna: financiacion	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Respuestas múltiples	Aplicar un método para separar las respuestas múltiples por medio de la creación de nuevas columnas basado en la técnica Dommies.

ID: 29	Nombre de la columna: t_hijos	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se creo esta columna nueva para el Dataset D2310	Esta pregunta no existe en el Dataset D2310 pero existe una pregunta compuesta entre esta y la #30 (embarazo_des) en donde existe una opción de respuesta No tengo hijos	Se puede responder en base a la pregunta #30

ID: 30	Nombre de la columna: embarazo_des	
Número de registros afectados: 189		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset D2310 es una pregunta compuesta entre si el estudiante tiene hijos y si considera que el embarazo es una causa de deserción en el Dataset D2320 es una ramificación de la pregunta anterior #29 (t_hijos) por lo tanto tiene 189 registros vacíos	En el dataset D2310 existe una opción de respuesta que dice No tengo hijos por medio de esto se puede asignar el valor en la respuesta 29 y dejar el campo vacío en esta pregunta

ID: 31	Nombre de la columna: dificultades_t	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 32	Nombre de la columna: a_familiar	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 33	Nombre de la columna: c_familiar	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 34	Nombre de la columna: e_acad	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Existe una diferencia de escritura en una respuesta D2310: Muy poco D2320: Muy poco efecto	Corrección de escritura

ID: 35	Nombre de la columna: d_acad	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 36	Nombre de la columna: h_semanal	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Error de escritura y existen otros rangos de respuesta en el Dataset D2320	Corrección de escritura

ID: 37	Nombre de la columna: a_profesores	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	Existe una diferencia de escritura ejemplo: D2320: Los profesores siempre están dispuestos a brindar ayuda D2310: Siempre dispuestos a brindar ayuda	Corrección de escritura

ID: 38	Nombre de la columna: m_calificacion	
Número de registros afectados: 483		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	En el Dataset D2320 las respuestas son numéricas y en el Dataset D2310 las respuestas son nominales	Realizar una asignación aleatoria utilizando la distribución en base a la variable numérica.

ID: 39	Nombre de la columna: p_profesores	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 40	Nombre de la columna: per_profesores	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 41	Nombre de la columna: motivacion	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 42	Nombre de la columna: ¿Qué tanto considera que la opinión de sus amigos influiría en la opción de una posible deserción estudiantil suya?	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se creo esta columna para D2320	Esta columna no existe en el Dataset D2320	Eliminarla

ID: 43	Nombre de la columna: acoso_psc	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 44	Nombre de la columna: c_acad	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 45	Nombre de la columna: v_semestre	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 46	Nombre de la columna: habilidades_pa	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 47	Nombre de la columna: adaptacion_u	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 48	Nombre de la columna: campus	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

ID: 49	Nombre de la columna: recomendacion_u	
Número de registros afectados: 0		
Novedad	Problema	Solución
Se realizo una unión entre los datasets D2310 y D2320	-	-

Segunda fase. Limpieza y ordenamiento: En esta sección se muestra el resultado de la fase de análisis de conflictos.

ID: 03	Nombre de la columna: HASH
Número de registros afectados: 483	
Novedad	
Se realizó un código en Python en donde se obtuvo los estudiantes que han respondido las 2 encuestas y esto se conservó en un nuevo dataset nombrado combinados.xlsx	

ID: 04	Nombre de la columna: carrera
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 05	Nombre de la columna: promedio_acad
Número de registros afectados: 483	
Novedad	
Se realizó una asignación aleatoria utilizando la distribución en base a la variable numérica. Para hallar cada valor	

ID: 07	Nombre de la columna: sisben
Número de registros afectados: 483	
Novedad	
Se realizó una asignación aleatoria utilizando la distribución en base a la variable numérica. Para hallar cada valor	

ID: 08	Nombre de la columna: transporte
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 09	Nombre de la columna: semestre
Número de registros afectados: 483	
Novedad	
Se realizó 2 tipos de soluciones. 1) Después de haber identificado a los estudiantes que habían respondido ambas encuestas se pudo identificar con exactitud a que semestre pertenecían al momento de responder la encuesta DD2310 los cuales eran 76 estudiantes. 2) Se realizó una asignación aleatoria utilizando la distribución en base a la variable numérica. Para hallar cada valor	

ID: 10	Nombre de la columna: o_voca
Número de registros afectados: 483	
Novedad	
Se eliminaron los registros de los estudiantes que no pertenecían al primer semestre en la encuesta DD2310. Ya que en la encuesta D2320 esta pregunta era ramificada y solo respondían los estudiantes del primer semestre	

ID: 11	Nombre de la columna: e_carrera
Número de registros afectados: 483	
Novedad	
Se eliminaron los registros de los estudiantes que no pertenecían al primer semestre en la encuesta D2310. Ya que en la encuesta D2320 esta pregunta era ramificada y solo respondían los estudiantes del primer semestre	

ID: 12	Nombre de la columna: i_carrera
Número de registros afectados: 483	
Novedad	
Se eliminaron los registros de los estudiantes que no pertenecían al primer semestre en la encuesta D2310. Ya que en la encuesta D2320 esta pregunta era ramificada y solo respondían los estudiantes del primer semestre	

ID: 13	Nombre de la columna: autopercepción
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 14	Nombre de la columna: aban_inter
Número de registros afectados: 281	
Novedad	
En el Dataset D2310 existía una opción de respuesta en donde los estudiantes respondían directamente no he interrumpido mis estudios, gracias a esta respuesta se pudo generar una nueva columna con respuesta binarias de si y no y así poder identificar a quienes si han desertado de sus estudios.	

ID: 15	Nombre de la columna: razon
Número de registros afectados: 483	
Novedad	
Se eliminaron todos los registros que tenían como respuesta no he interrumpido mis estudios y solo se conservaron quienes dieron razones de dicha interrupción.	

ID: 18	Nombre de la columna: c_universidad
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 19	Nombre de la columna: e_negativas
Número de registros afectados: 483	
Novedad	
Como existía la opción de respuestas múltiples, se optó por darle el mayor grado de relevancia a la primera respuesta del registro y las otras se eliminaron luego se realizó un estudio estadístico en unión con las respuestas de la siguiente columna g_afectacion	

ID: 20	Nombre de la columna: g_afectacion
Número de registros afectados: 281	
Novedad	
Se realizó un estudio estadístico en conjunto con la columna e_negativas para poder dar una asignación correcta basada en la media aritmética de esta columna y este fue asignado a los registros del Dataset D2310 en el cual no existía la columna g_afectacion	

ID: 22	Nombre de la columna: t_estudios
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 23	Nombre de la columna: ingresos
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 26	Nombre de la columna: p_cargo
Número de registros afectados: 483	
Novedad	
Se corrigió los errores de escritura directamente en Excel y las respuestas múltiples se solucionó por medio de una separación de por columnas con las respuestas principales luego en ellas se ingresó la información de respuesta de forma binaria basado en Dommies	

ID: 27	Nombre de la columna: financiacion
Número de registros afectados: 483	
Novedad	
Se realizó una separación de por columnas con las respuestas principales luego en ellas se ingresó la información de respuesta de forma binaria basado en Dommies	

ID: 28	Nombre de la columna: t_hijos
Número de registros afectados: 483	
Novedad	
En base a la columna #29 embarazo_des en donde existía una opción de respuesta que decía no tengo hijos se realizó un filtro y se le asignó la respuesta a esta columna	

ID: 29	Nombre de la columna: embarazo_des
Número de registros afectados: 189	
Novedad	
Se eliminaron las respuestas que decían no tengo hijos y se dejaron las otras respuestas dando a entender que estas personas tienen hijos	

ID: 33	Nombre de la columna: e_acad
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 34	Nombre de la columna: d_acad
Número de registros afectados: 483	
Novedad	
Se realizó una unión entre los datasets D2310 y D2320	

ID: 35	Nombre de la columna: h_semanal
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 36	Nombre de la columna: a_profesores
Número de registros afectados: 483	
Novedad	
Se corrigió de forma directa en Excel	

ID: 37	Nombre de la columna: m_calificacion
Número de registros afectados: 483	
Novedad	
Se realizó una asignación aleatoria utilizando la distribución en base a la variable numérica. Para hallar cada valor	

Aplicación de la metodología dummies en las preguntas de respuestas múltiples.

Nombre de la columna: carrera
carrera_Civil
carrera_Sistemas

Nombre de la columna: ID_s
ID_s_1
ID_s_2

Nombre de la columna: ID2
ID2_1
ID2_2
ID2_3
ID2_4
.....
ID2_481
ID2_482
ID2_483

Nombre de la columna: promedio_acad
promedio_acad_2.8
promedio_acad_3.0
promedio_acad_3.1
promedio_acad_3.2
promedio_acad_3.3
promedio_acad_3.4
promedio_acad_3.5
promedio_acad_3.6
promedio_acad_3.7
promedio_acad_3.8
promedio_acad_3.9
promedio_acad_4.0
promedio_acad_4.1
promedio_acad_4.2
promedio_acad_4.3
promedio_acad_4.4
promedio_acad_4.5
promedio_acad_4.6

Nombre de la columna: edad
edad_16
edad_17
edad_18
edad_20
edad_21
edad_22
edad_23
edad_24
edad_25
edad_26
edad_27
edad_28
edad_29
edad_30
edad_31
edad_32
edad_33
edad_34
edad_35
edad_38
edad_39
edad_42
edad_45

Nombre de la columna: sisben
sisben_A1
sisben_A2
sisben_A3
sisben_A4
sisben_A5
sisben_B1
sisben_B2
sisben_B3
sisben_B4
sisben_B5
sisben_B6
sisben_B7
sisben_C1
sisben_C10
sisben_C15
sisben_C17
sisben_C2
sisben_C3
sisben_C4
sisben_C5
sisben_C6
sisben_C7
sisben_D1
sisben_D12
sisben_D13
sisben_D14
sisben_D21
sisben_No tengo

Nombre de la columna: transporte
transporte_A pie
transporte_Bicicleta
transporte_Carro
transporte_Moto
transporte_Otro
transporte_Servicio público

Nombre de la columna: semestre
semestre_1
semestre_2
semestre_3
semestre_4
semestre_5
semestre_6
semestre_7
semestre_8
semestre_9
semestre_10

Nombre de la columna: o_voca
o_voca_Ninguno
o_voca_Por el colegio
o_voca_Por la universidad
o_voca_Por los padres u otro familiar
o_voca_Por un profesional especializado

Nombre de la columna: e_carrera
e_carrera_Amigos;
e_carrera_Facilidad de acceso al mercado laboral ;Amigos;
e_carrera_Facilidad de acceso al mercado laboral ;Interés por la disciplina de estudio;
e_carrera_Facilidad de acceso al mercado laboral ;Vocación o gusto propio;
e_carrera_Facilidad de acceso al mercado laboral;
e_carrera_Interés por la disciplina de estudio;
e_carrera_Interés por la disciplina de estudio;Facilidad de acceso al mercado laboral ;Vocación o gusto propio;
e_carrera_Interés por la disciplina de estudio;Vocación o gusto propio;
e_carrera_Interés por la disciplina de estudio;Vocación o gusto propio;Otro;
e_carrera_Otro;
e_carrera_Vocación o gusto propio;
e_carrera_Vocación o gusto propio;Facilidad de acceso al mercado laboral ;
e_carrera_Vocación o gusto propio;Facilidad de acceso al mercado laboral ;Interés por la disciplina de estudio;
e_carrera_Vocación o gusto propio;Facilidad de acceso al mercado laboral ;Interés por la disciplina de estudio;Amigos;Otro;
e_carrera_Vocación o gusto propio;Interés por la disciplina de estudio;
e_carrera_Vocación o gusto propio;Interés por la disciplina de estudio;Amigos;
e_carrera_Vocación o gusto propio;Interés por la disciplina de estudio;Otro;

Nombre de la columna: i_carrera
i_carrera_Estaba indeciso entre dos o tres elecciones de carreras
i_carrera_Estaba indeciso entre varias opciones de carrera
i_carrera_No tenía idea de qué estudiar pero quería hacerlo
i_carrera_No tenía ninguna idea sobre lo que quería estudiar
i_carrera_Si, tenía idea precisa
i_carrera_Sí, tenía idea clara

Nombre de la columna: autopercepcion
autopercepcion_Mucho
autopercepcion_Muy poco
autopercepcion_No me identifico
autopercepcion_Totalmente

Nombre de la columna: aban_inter
aban_inter_No
aban_inter_Sí

Nombre de la columna: razon
razon_Dificultades académicas;
razon_Dificultades académicas;Problemas financieros;
razon_Falta de apoyo o orientación por parte de la universidad;
razon_Falta de interés en la carrera o programa de estudios;
razon_Falta de interés en la carrera o programa de estudios;Problemas personales o familiares;
razon_Falta de interés por la carrera;
razon_Falta de motivación;
razon_Falta de motivación;Problemas financieros;Falta de apoyo o orientación por parte de la universidad;
razon_Falta de motivación;Problemas financieros;Problemas personales o familiares;
razon_Problemas de salud mental;
razon_Problemas de salud mental;Problemas personales o familiares;
razon_Problemas financieros;
razon_Problemas financieros;Dificultades académicas;
razon_Problemas financieros;Dificultades académicas;Falta de apoyo o orientación por parte de la universidad;
razon_Problemas financieros;Dificultades académicas;Problemas personales o familiares;Falta de motivación;
razon_Problemas financieros;Problemas de salud mental;
razon_Problemas financieros;Problemas personales o familiares;
razon_Problemas financieros;Problemas personales o familiares;Problemas de salud mental;Dificultades académicas;
razon_Problemas personales o familiares;
razon_Problemas personales o familiares;Problemas de salud mental;
razon_Problemas personales o familiares;Problemas financieros;

Nombre de la columna: c_universidad
c_universidad_Negativamente
c_universidad_No afectó
c_universidad_No aplica
c_universidad_No sé aún
c_universidad_Positivamente

Nombre de la columna: e_negativas
e_negativas_Fallecimiento de la madre o del padre
e_negativas_Ingresar al mundo laboral
e_negativas_Ninguna
e_negativas_Otros eventos que alteraron sustancialmente el modo o hábitos de vida
e_negativas_Problemas de carácter psicológico (depresión, estrés, ansiedad, desánimo, entre otros)
e_negativas_Pérdida del trabajo
e_negativas_Separación/divorcio de los padres
e_negativas_Ser madre o padre

Nombre de la columna: g_afectacion
g_afectacion_1
g_afectacion_2
g_afectacion_3
g_afectacion_4
g_afectacion_5
g_afectacion_6
g_afectacion_7
g_afectacion_8
g_afectacion_9
g_afectacion_10

Nombre de la columna: r_carrera
r_carrera_Cambiarse de carrera;
r_carrera_Cambiarse de carrera;Cancelar el semestre;
r_carrera_Cambiarse de carrera;Ninguno;
r_carrera_Cambiarse de carrera;Retirarse definitivamente de la universidad;
r_carrera_Cancelar el semestre;
r_carrera_Cancelar el semestre;Cambiarse de carrera;
r_carrera_Cancelar el semestre;Cancelar una materia o más;
r_carrera_Cancelar el semestre;Retirarse definitivamente de la universidad;
r_carrera_Cancelar un curso o más;
r_carrera_Cancelar un curso o más;Cancelar el semestre;
r_carrera_Cancelar un curso o más;Cancelar el semestre;Cambiarse de carrera;Retirarse definitivamente de la universidad;
r_carrera_Cancelar una materia o más;
r_carrera_Cancelar una materia o más;Cancelar el semestre;
r_carrera_Cancelar una materia o más;Cancelar el semestre;Cambiarse de carrera;
r_carrera_Cancelar una materia o más;Cancelar el semestre;Cambiarse de carrera;Retirarse definitivamente de la universidad;
r_carrera_Cancelar una materia o más;Cancelar el semestre;Retirarse definitivamente de la universidad;
r_carrera_Cancelar una materia o más;Retirarse definitivamente de la universidad;
r_carrera_Ninguno;
r_carrera_Retirarse definitivamente de la universidad;
r_carrera_Retirarse definitivamente de la universidad;Cambiarse de carrera;Cancelar el semestre;

Nombre de la columna: t_estudios
t_estudios_Me afecta bastante, de manera negativa
t_estudios_Me afecta bastante, de manera positiva
t_estudios_Me afecta muy poco, de manera negativa
t_estudios_Me afecta poco, de manera positiva
t_estudios_No me afecta (Si trabajo)
t_estudios_No trabajo

Nombre de la columna: ingresos
ingresos_Hasta un SMLMV (\$1.160.000)
ingresos_\$1.160.001 - \$2.320.000
ingresos_\$2.320.001 - \$3.480.000
ingresos_\$3.480.001 - \$4.640.000
ingresos_Más de \$4.640.000
ingresos_No trabajo

Nombre de la columna: dificultades_t
dificultades_t_Muchas veces
dificultades_t_Nunca
dificultades_t_Pocas veces
dificultades_t_Siempre

Nombre de la columna: m_residencia
m_residencia_Acacias
m_residencia_Cabuyaro
m_residencia_Castilla la Nueva
m_residencia_Cubarral
m_residencia_Cumaral
m_residencia_El Calvario
m_residencia_El Dorado
m_residencia_Granada
m_residencia_Guamal
m_residencia_Lejanías
m_residencia_Mesetas
m_residencia_No nació en el departamento
m_residencia_Puerto Gaitán
m_residencia_Puerto López
m_residencia_Puerto Rico
m_residencia_Restrepo
m_residencia_San Juan de Arama
m_residencia_San Martín
m_residencia_Villavicencio
m_residencia_Vista Hermosa

Nombre de la columna: h_semanal
h_semanal_0-2
h_semanal_2-4
h_semanal_4 - 6
h_semanal_6-8
h_semanal_8-10
h_semanal_10-12
h_semanal_ más 12

Nombre de la columna: t_hijos
t_hijos_NO
t_hijos_SI

Nombre de la columna: embarazo_des
embarazo_des_Altamente probable
embarazo_des_Muy probable
embarazo_des_Nada probable
embarazo_des_Poco probable

Nombre de la columna: financiacion
financiacion_Beca;
financiacion_Beca;Familiar;
financiacion_Beca;Trabajo propio;Mis padres (o familiares) me financian;
financiacion_Crédito;
financiacion_Crédito;Beca;Familiar;Trabajo propio;
financiacion_Crédito;Familiar;
financiacion_Crédito;Familiar;Trabajo propio;
financiacion_Crédito;Mis padres (o familiares) me financian;
financiacion_Crédito;Trabajo propio;
financiacion_Crédito;Trabajo propio;Familiar;
financiacion_Crédito;Trabajo propio;Mis padres (o familiares) me financian;
financiacion_Familiar;
financiacion_Familiar;Beca;
financiacion_Familiar;Crédito;
financiacion_Familiar;Trabajo propio;
financiacion_Mis padres (o familiares) me financian;
financiacion_Mis padres (o familiares) me financian;Beca;
financiacion_Mis padres (o familiares) me financian;Crédito;
financiacion_Mis padres (o familiares) me financian;Crédito;Beca;
financiacion_Mis padres (o familiares) me financian;Crédito;Trabajo propio;
financiacion_Mis padres (o familiares) me financian;Trabajo propio;
financiacion_Trabajo propio;
financiacion_Trabajo propio;Crédito;
financiacion_Trabajo propio;Familiar;
financiacion_Trabajo propio;Mis padres (o familiares) me financian;

Nombre de la columna: a_familiar
a_familiar_Demasiado
a_familiar_Mucho
a_familiar_Muy poco
a_familiar_Nada

Nombre de la columna: c_familiar
c_familiar_Buen estudiante
c_familiar_Mal estudiante
c_familiar_Muy buen estudiante
c_familiar_Pésimo estudiante

Nombre de la columna: e_acad
e_acad_Demasiado
e_acad_Mucho
e_acad_Muy poco efecto
e_acad_Ninguno

Nombre de la columna: d_acad
d_acad_Muchas veces
d_acad_Nunca
d_acad_Pocas veces
d_acad_Siempre

Nombre de la columna: a_profesores
a_profesores_A veces dispuestos a ayudar
a_profesores_Nunca dispuestos a ayudar
a_profesores_Rara vez dispuestos a ayudar
a_profesores_Siempre dispuestos a ayudar

Nombre de la columna: a_profesores
c_profesores_En cierta medida
c_profesores_No estoy seguro/a
c_profesores_No, no influye
c_profesores_Sí, definitivamente

motivacion _8
motivacion _9
motivacion _10

Nombre de la columna: m_calificacion
m_calificacion_1
m_calificacion_2
m_calificacion_3
m_calificacion_4
m_calificacion_5
m_calificacion_6
m_calificacion_7
m_calificacion_8
m_calificacion_9
m_calificacion_10

Nombre de la columna: acoso_psc
acoso_psc_1
acoso_psc_2
acoso_psc_3
acoso_psc_4
acoso_psc_5
acoso_psc_6
acoso_psc_7
acoso_psc_8
acoso_psc_9
acoso_psc_10

Nombre de la columna: p_profesores
p_profesores_1
p_profesores_2
p_profesores_3
p_profesores_4
p_profesores_5
p_profesores_6
p_profesores_7
p_profesores_8
p_profesores_9
p_profesores_10

Nombre de la columna: ac_acad
ac_acad_1
ac_acad_2
ac_acad_3
ac_acad_4
ac_acad_5
ac_acad_6
ac_acad_7
ac_acad_8
ac_acad_9
ac_acad_10

Nombre de la columna: per_profesores
per_profesores_1
per_profesores_2
per_profesores_3
per_profesores_4
per_profesores_5
per_profesores_6
per_profesores_7
per_profesores_8
per_profesores_9
per_profesores_10

Nombre de la columna: v_semestre
v_semestre_1
v_semestre_2
v_semestre_3
v_semestre_4
v_semestre_5
v_semestre_6
v_semestre_7
v_semestre_8
v_semestre_9
v_semestre_10

Nombre de la columna: motivacion
motivacion_1
motivacion_2
motivacion_3
motivacion_4
motivacion_5
motivacion_6
motivacion_7

Nombre de la columna: habilidades_pa
habilidades_pa_1
habilidades_pa_2
habilidades_pa_3
habilidades_pa_4
habilidades_pa_5
habilidades_pa_6
habilidades_pa_7
habilidades_pa_8
habilidades_pa_9
habilidades_pa_10

Nombre de la columna: recomendación_u
recomendación_u_1
recomendación_u_2
recomendación_u_3
recomendación_u_4
recomendación_u_5
recomendación_u_6
recomendación_u_7
recomendación_u_8
recomendación_u_9
recomendación_u_10

Nombre de la columna: adaptación_u
adaptacion_u_1
adaptacion_u_2
adaptacion_u_3
adaptacion_u_4
adaptacion_u_5
adaptacion_u_6
adaptacion_u_7
adaptacion_u_8
adaptacion_u_9
adaptacion_u_10

Nombre de la columna: campus
campus_1
campus_2
campus_3
campus_4
campus_5
campus_6
campus_7
campus_8
campus_9
campus_10

Nombre de la columna: p_cargo
p_cargo_Hermanos
p_cargo_Hijos
p_cargo_Ninguna
p_cargo_Padres
p_cargo_Padres;Hermanos;
p_cargo_Padres;Hijos;Pareja (conyuge);
p_cargo_Padres;Ninguna;
p_cargo_Pareja
p_cargo_Pareja (conyuge);

Transformación de datos categóricos a numéricos.

Nombre de la columna: carrera	
Ing Civil	0
Inge Sistemas	1

Nombre de la columna: sisben	
A1	0
A2	1
A3	2
A4	3
A5	4
B1	5
B2	6
B3	7
B4	8
B5	9
B6	10
B7	11
C1	12
C10	13
C15	14
C17	15
C2	16
C3	17
C4	18
C5	19
C6	20
C7	21
D1	22
D12	23
D13	24
D14	25
D21	26
No tengo	27

Nombre de la columna: transporte	
A pie	0
Bicicleta	1
Carro	2
Moto	3
Otro	4
Servicio público	5

Nombre de la columna: o_voca	
Ninguno	0
Por el colegio	1
Por la universidad	2
Por los padres u otro familiar	3
Por un profesional especializado	4
nan	5

Nombre de la columna: autopercepcion	
Mucho	0
Muy poco	1
No me identifico	2
Totalmente	3

Nombre de la columna: c_universidad	
Negativamente	0
No afectó	1
No aplica	2
No sé aún	3
Positivamente	4

Nombre de la columna: e_negativas	
Fallecimiento de la madre o del padre	0
Ingresar al mundo laboral	1
Ninguna	2
Otros eventos que alteraron sustancialmente el modo o hábitos de vida	3
Problemas de carácter psicológico (depresión, estrés, ansiedad, desánimo, entre otros)	4
Pérdida del trabajo	5
Separación/divorcio de los padres	6
Ser madre o padre	7

Nombre de la columna: aban_inter	
No	0
Si	1

Nombre de la columna: h_semanal	
más 12	0
0-2	1
10-12	2
2-4	3
4 - 6	4
6-8	5
8-10	6

Nombre de la columna: a_profesores	
En cierta medida	0
No estoy seguro/a	1
No, no influye	2
Sí, definitivamente	3

Nombre de la columna: a_profesores	
A veces dispuestos a ayudar	0
Nunca dispuestos a ayudar	1
Rara vez dispuestos a ayudar	2
Siempre dispuestos a ayudar	3

Nombre de la columna: t_estudios	
Me afecta bastante, de manera negativa	0
Me afecta bastante, de manera positiva	1
Me afecta muy poco, de manera negativa	2
Me afecta poco, de manera positiva	3
No me afecta (Si trabajo)	4
No trabajo	5

Nombre de la columna: ingresos	
\$1.160.001 - \$2.320.000	0
\$2.320.001 - \$3.480.000	1
\$3.480.001 - \$4.640.000	2
Hasta un SMLMV (\$1.160.000)	3
Más de \$4.640.000	4
No trabajo	5

Nombre de la columna: m_residencia	
Acacías	0
Cabuyaro	1
Castilla la Nueva	2
Cubarral	3
Cumaral	4
El Calvario	5
El Dorado	6
Granada	7
Guamal	8
Lejanías	9
Mesetas	10
No nació en el departamento	11
Puerto Gaitán	12
Puerto López	13
Puerto Rico	14
Restrepo	15
San Juan de Arama	16
San Martín	17
Villavicencio	18
Vista Hermosa	19

Nombre de la columna: t_hijos	
No	0
Si	1

Nombre de la columna: embarazo_des	
Altamente probable	0
Muy probable	1
Nada probable	2
Poco probable	3
Nan	4

Nombre de la columna: dificultades_t	
Muchas veces	0
Nunca	1
Pocas veces	2
Siempre	3

Nombre de la columna: a_familiar	
Demasiado	0
Mucho	1
Muy poco	2
Nada	3
Relativamente poco	4

Nombre de la columna: c_familiar	
Buen estudiante	0
Mal estudiante	1
Muy buen estudiante	2
Pésimo estudiante	3

Nombre de la columna: e_acad	
Demasiado	0
Mucho	1
Muy poco efecto	2
Ninguno	3

Nombre de la columna: d_acad	
Muchas veces	0
Nunca	1
Pocas veces	2
Siempre	3