

Revisión Sistemática: Machine Learning en la Predicción de Deserción Académica

Manuel S. Asto-Lázaro¹, Henry P. Bermejo-Terrones¹

mastola23@ucvvirtual.edu.pe; hbermejot@ucv.edu.pe

¹ Grupo de Investigación Tendencia e Innovación en Ingeniería de Sistemas-Trujillo, Universidad César Vallejo, Trujillo, La Libertad 13001, Perú.

Pages: 463-476

Resumen: Este trabajo sostuvo como objetivo la realización de una revisión sistemática, sobre el uso del Machine Learning en la predicción de deserción académica, para ello se plantearon 4 interrogantes de investigación y haciendo uso de la metodología conocida como PRISMA, se hallaron 30 artículos que pasaron los criterios de exclusión e inclusión planteados, además se utilizó el software Zotero (Gestor de referencias bibliográficas) para facilitar la gestión de los artículos hallados. Los resultados expresaron que el Machine Learning puede ser aplicado en diferentes sectores como el financiero y educativo, además que las variables más utilizadas para predecir deserción académica fueron el sexo del estudiante (60%), promedio de calificaciones (53.33%), edad (43.33%), lugar de procedencia (33.33%), tipo de colegio de procedencia (26.67%), situación laboral (23.33%) y estado civil (23.33%), también se evidencio que las técnicas más comunes en la predicción de deserción académica fueron las de Árbol de Decisión (66.67%) y Redes Neuronales Artificiales (50%), y por último se evidencia que las métricas más comunes en la evaluación de modelos predictivos de deserción académica son la precisión (63.33%), exactitud (60%) y sensibilidad (50%).

Palabras-clave: Aprendizaje Automático, Predicción, Deserción Académica, Revisión Sistemática, Inteligencia Artificial.

Systematic Review: Machine Learning in Academic Dropout Prediction.

Abstract: The goal of this work was to elaborate a systematic review on the use of Machine Learning in the prediction of academic dropout, for which 4 research questions were raised and using the methodology known as PRISMA, 30 articles were found that passed the proposed exclusion and inclusion criteria, and the Zotero software (Bibliographic Reference Manager) was used to facilitate the management of the articles found. The results expressed that Machine Learning can be applied in distinct sectors such as financial and educational, also that the most used variables to predict academic dropout were the student's sex (60%), grade point average (53.33%), age (43.33%), place of origin (33.33%), type of school of origin (26.67%), employment situation (23.33%) and marital status (23.33%), finally, it was evidenced that the most common techniques in the prediction of academic

dropout were those of Decision Tree (66.67%) and Artificial Neural Network (50%), and finally, it is evident that the most common metrics in the evaluation of predictive models of academic dropout are precision (63.33%), accuracy (60%), and sensitivity (50%).

Keywords: Machine Learning, Prediction, Academic Dropout, Systematic Review, Artificial Intelligence.

1. Introducción

La deserción en universidades ha incrementado de manera notable y sobre todo después de la pandemia de COVID-19, debido que al estar en aislamiento se originó una crisis económica en gran parte de las familias, lo que trae como consecuencia la limitación de beneficios sociales y personales como la disminución de ingresos, disminución de la productividad, el incremento de violencia e inseguridad, etc. (Guzmán et al. 2022).

Valero et al. (2022), da a entender que la deserción académica refiere a cuando se detiene de forma provisional o completa la educación de un estudiante y cita a Rico indicando que posiblemente la deserción académica sea el resultado de la implicación de varios factores como económicos, sociales, académicos, demográficos, entre otros; siendo considerada la deserción académica un fenómeno difícil de definir debido a que es poli causal.

Las Universidades son imprescindibles para el progreso de la economía moderna dado que dotan a los alumnos de una amplia gama de competencias y habilidades sociales, profesionales, técnicas y disciplinares que los preparan para desempeñarse en diversas funciones laborales (Urbina et al., 2020). Es por ello que cuando un alumno deja sus estudios, genera un indicador que preocupa a las instituciones educativas, en consecuencia las universidades requieren identificar e implementar sistemas para disminuir la deserción académica (Valero et al., 2022).

La posibilidad de usar el entendimiento de datos para la mejora de los sistemas educativos ha desencadenado el aumento de investigación en el campo de la Minería de Datos Educativos, más conocido como Educational Data Mining (EDM), por ende, el uso del aprendizaje automático también ha aumentado de manera significativa, debido a que se puede hacer uso de estos datos para la predicción y simulación de procesos académicos (Alhazmi & Sheneamer, 2023).

El uso del Machine Learning en la predicción de deserción académica ha evidenciado ser efectivo, sin embargo, existen tres principales factores a tomar en cuenta cuando se usa este enfoque: el primero está referido a la selección de atributos que influyen en la deserción educativa, el segundo referido a la selección del algoritmo de Machine Learning a implementar y por último las métricas para la evaluación de veracidad de los resultados obtenidos (Khalid et al., 2022).

El presente artículo se centró en identificar el uso de Machine Learning en la predicción de deserción académica, donde se realizó una revisión sistemática y se recopiló información de 30 artículos, además se utilizó las directrices ofrecidas por el método PRISMA. Para llevar a cabo la investigación se plantearon 5 preguntas. ¿Qué se sabe acerca del Machine Learning?, ¿Qué variables se pueden tomar en cuenta en la predicción de deserción

académica?, ¿Qué técnicas de Machine Learning se pueden utilizar en la predicción de deserción académica? Y ¿Qué métricas se pueden utilizar para evaluar modelos en la predicción de deserción académica?

2. Trabajos relacionados

Kwasi & Buabeng (2022), tuvieron como objetivo la implementación de un modelo utilizando un algoritmo de Machine Learning en la predicción de las tasas de deserción, utilizaron el cuestionario mediante la herramienta Google Forms para la recolección de datos, donde se recopiló 1239 respuestas sobre algunos datos del alumnado de la Universidad de Educación de Winneba, Ghana, además se usó la metodología CRISP-DM, tras la evaluación de 4 algoritmos de clasificación, se obtuvo como resultado una precisión de 0.623 con el modelo utilizando Support Vector Machine, por otro lado con el modelo utilizando Bosques Aleatorios se alcanzó una precisión de 0.708, con el modelo utilizando Árbol de Decisión se alcanzó una precisión de 0.649, y con el modelo utilizando Perceptrón Multicapa se consiguió 0.642, finalmente se concluye que el modelo utilizando Bosques Aleatorios comprendió un mejor desempeño frente a los otros algoritmos.

Valero et al. (2022), tuvo como objetivo determinar el algoritmo de Machine Learning con mayor rendimiento para la detección de deserción universitaria entre 2018 y 2021, en Perú, la investigación fue de tipo aplicada con un diseño descriptivo, tuvo como población a 652 alumnos de la UNTELS (Universidad Nacional Tecnológica en Lima Sur), se empleó el cuestionario y la ficha de observación en la recopilación de datos, además también se usó Python para el procesamiento de los datos, se consiguió como resultados que el algoritmo Support Vector Machine alcanzó una precisión de 0.875, el algoritmo Regresión Logística consiguió una precisión de 0.8125, el algoritmo Árbol de Decisión tuvo una precisión de 0.8125 y el algoritmo K Nearest Neighbors tuvo una precisión de 0.90625, por último concluye que el algoritmo K Nearest Neighbor tiene mejor desempeño al momento de pronosticar la deserción universitaria, además se evidencio que el bajo rendimiento académico es uno de los causantes que más influyen en la deserción universitaria.

Vega et al. (2022), tuvo como objetivo la implementación de un sistema inteligente para la disminución de deserción de los alumnos en la Universidad Nacional Mayor de San Marcos, tuvo como población los datos registrados de los estudiantes de Sistemas e Informática entre 2004 y 2014 (1300 instancias), obtuvo como resultados una exactitud de 90,34 % y precisión de 95,91 % durante el proceso de aprendizaje del sistema inteligente, finalmente concluyó que el sistema inteligente es considerado válido para la predicción de deserción de estudiantes y además identificó que las variables más predominantes en la deserción académica fueron: el promedio histórico, promedio ponderado del último ciclo y el número de créditos aprobados.

Medina et al. (2020), tuvo como finalidad la propuesta de desarrollo de un modelo capaz de determinar los factores influyentes en la deserción de los universitarios mediante un análisis predictivo en el Perú, para su investigación se recolectaron datos de 500 alumnos de pregrado, además se comparó la técnica de redes bayesianas frente a la técnica de árboles de decisión obteniendo como resultados un 67.10 % de precisión en las

redes bayesianas frente a un 61.92 % de precisión en los árboles de decisión, finalmente concluyó que se logró la creación de un modelo predictivo capaz de determinar la probabilidad de deserción de los universitarios, además identificó que las variables más influyentes en la deserción de los alumnos estaban asociadas a: que si el estudiante era deportista, si tenía vivienda propia, las calificaciones y el sexo del estudiante.

3. Método de revisión

PRISMA (Preferred Reporting Items for Systematic reviews and Meta-Analyses), es considerada como una guía de presentación de informes para la emisión de revisiones sistemáticas, fue publicada en 2009 y sustituida por la versión 2020, diseñada para apoyar a documentar el porqué de la revisión sistemática, que se hizo y que se encontró, además establece una lista de verificación de 27 ítems (Page et al., 2021).

3.1. Interrogantes a Investigar

Para el desarrollo de la presente revisión sistemática se planteó las posteriores interrogantes (RQ):

- RQ1. ¿Qué se sabe acerca del Machine Learning?
- RQ2. ¿Qué variables se pueden tomar en cuenta en la predicción de deserción académica?
- RQ3. ¿Qué técnicas de Machine Learning se pueden utilizar en la predicción de deserción académica?
- RQ4. ¿Qué métricas se pueden utilizar para evaluar modelos en la predicción de deserción académica?

3.2. Fuentes y Tácticas de Búsqueda

En la indagación de los artículos que ayudaron en la elaboración de la presente revisión sistemática se utilizó diversas bases de datos digitales (fuentes) tales como: EBSCO, IEEE Xplore, ProQuest y Scopus; así mismo se visualizan, los descriptores de búsqueda empleados en la revisión sistemática, en la tabla 1.

Descriptor	
Español	Inglés
Aprendizaje Automático	Machine Learning
Predicción de Deserción	Dropout Prediction
Deserción Académica	Academic Dropout

Tabla 1 – Descriptores de búsqueda en idioma español e inglés.

En la tabla número 2, se visualiza las ecuaciones de búsqueda utilizadas y la cantidad de artículos obtenidos en cada base de datos digital.

Fuente	Ecuación de Búsqueda	Nº de artículos
EBSCO	((Aprendizaje Automático)) OR ((Machine Learning)) AND ((Predicción)) OR ((Prediction)) AND ((Deserción Académica)) OR ((Academic Dropout))	1,796
IEEE Xplore	("All Metadata":Aprendizaje Automático) OR ("All Metadata":Machine Learning) AND ("All Metadata":Predicción) OR ("All Metadata":Prediction) AND ("All Metadata":Deserción Académica) OR ("All Metadata":Academic Dropout)	211
ProQuest	(Aprendizaje Automático) OR (Machine Learning) AND Predicción OR Dropout AND (Deserción Académica) OR (Academic Dropout)	15,852
Scopus	(TITLE-ABS-KEY (aprendizaje AND automático) OR TITLE-ABS-KEY (machine AND learning) AND TITLE-ABS-KEY (predicción) OR TITLE-ABS-KEY (prediction) AND TITLE-ABS-KEY (deserción AND académica) OR TITLE-ABS-KEY (academic AND dropout))	95
Total		17,954

Tabla 2 – Ecuaciones de búsqueda y cantidad de artículos obtenidos por cada fuente.

3.3. Criterios de Exclusión

Para la obtención de resultados más apropiados en la investigación se establecieron criterios de exclusión (CE), a continuación, son mencionados:

CE1: Artículos no publicados entre 2015 y 2023.

CE2: Artículos sin acceso abierto.

CE3. Artículos sin estar vinculados al tema de investigación.

CE4. Artículos sin texto completo disponible.

CE5. Artículos de revistas fuera del ranking Scimago.

Tales criterios de exclusión (CE) sirvieron como filtros para la elección de los artículos más significativos en la realización de la revisión sistemática. A continuación, se visualiza el flujo de los pasos que se llevaron a cabo para la elección de los artículos encontrados.

3.4. Selección de artículos.

En la elección de los artículos que ayudaron en la realización de la revisión sistemática se tomaron en cuenta los criterios de exclusión (CE) mencionados anteriormente en el punto 3.3., tras la aplicación de dichos filtros (CE) se encontraron 30 artículos de estudio de diferentes bases de datos digitales: EBSCO (10), IEEE Xplore (5), Proquest (5) y Scopus (10).




Figura 1 – Flujo llevado a cabo para la elección de los artículos




Figura 2 – Porcentaje de fuente de búsqueda.

3.5. Evaluación de la Calidad

Con relación a los artículos encontrados se aplicaron los criterios de calidad (QA) que se muestran a continuación.

QA1: ¿Se evidencia información de antecedentes en el documento?

QA2: ¿Se manifiesta el objetivo de la investigación?

QA3: ¿Se evidencia palabras clave relacionadas al tema de investigación?

QA4: ¿Se evidencia tablas que demuestren los resultados de la investigación?

3.6. Tácticas para la Recolección de Datos

Aquí se recopiló datos de los artículos seleccionados que fueron sacados de las diferentes bases de datos digitales (EBSCO, IEEE, ProQuest y Scopus) y se utilizó el software llamado Zotero (Gestor de referencias bibliográficas) para la gestión y administración de cada artículo a través de creación de colecciones y notas, lo que permitió clasificar de manera más ordenada los diferentes artículos hallados.

Titulo	Creador
> A Neural Network-Based System to Predict Early MOOC Dropout	Sraidi et al.
> A Real-Life Machine Learning Experience for Predicting University Dropout at Different Stages Using Academi...	Fernández-García et al.
> An early warning system to identify and intervene online dropout learners	Bañeres et al.
> Construcción De Un Modelo De Alerta Temprana Para La Detección De Estudiantes En Riesgo De Deserción De...	Henríquez C. y Escobar R.
> Deep Learning Model to Predict Students Retention Using BLSTM and CRF	Uliyan et al.
> Deserción de estudiantes, factores asociados con árboles de decisión: caso Escuela de Postgrado 1de una Uni...	Díaz et al.
> Deserción escolar universitaria: Patrones para prevenirla aplicando minería de datos educativa	Urbina-Nájera et al.
> Deserción universitaria: Evaluación de diferentes algoritmos de Machine Learning para su predicción	Valero Cajahuanca et al.
> Early Predicting of Students Performance in Higher Education	Alhazmi y Sheneamer
> Enhanced Model for Predicting Student Dropouts in Developing Countries Using Automated Machine Learni...	Mnyawami et al.
> Intelligent System to Predict University Students Dropout	Vega et al.
> IoT System for School Dropout Prediction Using Machine Learning Techniques Based on Socioeconomic Data	Freitas et al.
> Machine Learning Prediction of University Student Dropout: Does Preference Play a Key Role?	Segura et al.
> Modelo de predicción de la deserción universitaria mediante analítica de datos: Estrategia para la sustentabili...	Guerra et al.
> Modelo predictivo para reducir el índice de deserción de estudiantes universitarios en el Perú: Redes Bayesian...	Medina et al.
> Modelos de clasificación para reconocer patrones de deserción en estudiantes universitarios: Classification m...	Zárate Valderrama et al.
> Modelos predictivos de riesgo académico en carreras de computación con minería de datos educativos: Predi...	Ayala Franco et al.
> Multi-Class Phased Prediction of Academic Performance and Dropout in Higher Education	Martins et al.
> Predicción temprana de deserción mediante aprendizaje automático en cursos profesionales en línea	Urteaga et al.
> Predicting Student Dropout and Academic Success	Realinho et al.
> Predicting student enrolments and attrition patterns in higher educational institutions using machine learning	Shilbayeh y Abonamah
> Predicting student's dropout in university classes using two-layer ensemble machine learning approach: A no...	Niyogisubizo et al.
> Predicting Students at Risk of Dropout in Technical Course Using LMS Logs	Tamada et al.
> Prediction of Student Dropout in E-Learning Program Through the Use of Machine Learning Method	Tan y Shao
> Prediction of Students' Academic Performance Based on Courses' Grades Using Deep Neural Networks	Nabil et al.
> Student Dataset from Tecnológico de Monterrey in Mexico to Predict Dropout in Higher Education	Alvarado-Uribe et al.
> Supporting Decision-Making Process on Higher Education Dropout by Analyzing Academic, Socioeconomic, ...	Gutierrez-Pachas et al.
> The Role of Machine Learning in Identifying Students At-Risk and Minimizing Failure	Pek et al.
> Towards a Students' Dropout Prediction Model in Higher Education Institutions Using Machine Learning Algo...	Oqaidi et al.
> Using Machine Learning Techniques to Predict Learner Drop-out Rate in Higher Educational Institutions	Dake y Buabeng-Andoh

Figura 3 – Artículos revisados en Zotero




Figura 4 – Colecciones por fuente de búsqueda en el software Zotero

3.7. Síntesis de los Hallazgos

Luego de la recopilación de datos, que fueron extraídos de los 30 artículos encontrados, se dio respuesta a las interrogantes de investigación planteadas en el punto 3.1. Para la interrogante RQ1 se recaudó información referida a los conceptos del Machine Learning. Para la interrogante RQ2 se recopiló información sobre las metodologías usadas en la predicción de deserción académica mediante Machine Learning donde se presenta en una tabla las metodologías más recurrentes en los artículos encontrados. Para la interrogante RQ3 se recopiló información sobre las variables usadas en la predicción de deserción académica donde se presenta en una tabla de manera resumida y generalizada las variables más recurrentes en los artículos encontrados. Para la interrogante RQ4 se recopiló información sobre las técnicas de Machine Learning usadas en la predicción de deserción académica donde se presenta en una tabla las técnicas más recurrentes en los artículos encontrados. Para la interrogante RQ5 se recaudó información sobre las métricas usadas en la evaluación de modelos en la predicción de deserción académica donde se presenta en una tabla las métricas más recurrentes en los artículos encontrados.

4. Resultados y Discusiones

Se obtuvo como resultado 30 artículos que fueron utilizados en la revisión sistemática, en la tabla 3 se visualiza los continentes de origen de los artículos hallados.

Continente	Cantidad	Porcentaje
Asia	7	23 %
América	14	47 %
África	5	17 %
Europa	4	13 %
Total	30	100 %

Tabla 3 – Países de origen de los artículos revisados

A continuación, se da respuesta a los problemas de investigación planteados en el punto 3.1.

RQ1. ¿Qué se sabe acerca del Machine Learning?

En el artículo de Díaz et al. (2022), se menciona que el Machine Learning o en español conocido como Aprendizaje Automático es considerado como una parte de la inteligencia artificial enfocada en la creación de sistemas con la capacidad de aprender por sí mismos partiendo de una fuente de datos.

El Machine Learning se cataloga en tres principales tipos de aprendizaje: el supervisado, no supervisado y el semisupervisado. El aprendizaje supervisado se caracteriza porque se mapea previamente tanto las entradas como las salidas de datos mientras que en el aprendizaje no supervisado se mapean solo las entradas de datos y no se conocen las

salidas, por otro lado el aprendizaje semisupervisado implica la mezcla del aprendizaje supervisado y no supervisado (Segura et al., 2022).

Además el Machine Learning ha sido aplicado a varios sectores y campos de estudio como en el reconocimiento de voz, la clasificación de imágenes, minería de datos, predicciones de abandono, sector financiero, educativo, medicina, etc. (Nabil et al., 2021).

RQ2. ¿Qué variables se pueden tomar en cuenta en la predicción de deserción académica?

Las variables que se pueden tomar en cuenta en la predicción de deserción académica según los resultados obtenidos en la revisión sistemática se visualizan en la tabla 5, donde se puede resumir que el sexo (60%), promedios de calificaciones (53.33%), edad (43.33%), lugar de procedencia (33.33%), colegio de procedencia (26.67%) y situación laboral (23.33%) son las variables que más se repiten en los 30 artículos encontrados.

Variables	Cantidad	Porcentaje
<i>Sexo</i>	18	60 %
<i>Promedio de calificaciones</i>	16	53.33 %
<i>Edad</i>	13	43.33 %
<i>Lugar de procedencia</i>	10	33.33 %
<i>Tipo de colegio de procedencia</i>	8	26.67 %
<i>Situación laboral</i>	7	23.33 %
<i>Estado civil</i>	7	23.33 %
<i>Examen de admisión</i>	6	20 %
<i>Educación del padre / Educación de la madre</i>	6	20 %
<i>Grado</i>	6	20 %
<i>Repitencia de asignaturas</i>	5	16.67 %
<i>Ocupación del padre / Ocupación de la madre</i>	5	16.67 %
<i>Asistencia</i>	5	16.67 %
<i>Preparacion preuniversitaria</i>	4	13.33 %
<i>Créditos aprobados</i>	4	13.33 %
<i>Miembros en la familia</i>	4	13.33 %

Tabla 4 – Variables utilizadas en la predicción de deserción académica.

RQ3. ¿Qué técnicas de Machine Learning se pueden utilizar en la predicción de deserción académica?

Valero et al. (2022), da a entender que las técnicas de Machine Learning contribuyen en el proceso de aprendizaje de una máquina a través de la generación de un modelo matemático.

La tabla 6, muestra algunas de las diversas técnicas de Machine Learning que se usan en la predicción de deserción académica, donde se puede resumir que Árbol de Decisión (66,67%), Red Neuronal Artificial (50%), Máquina de Vectores de Soporte (40%), Bosque Aleatorio (40%) y Regresión Logística (33.33%) son las técnicas que más se repiten en los 30 artículos encontrados.

Técnica de Machine Learning	Cantidad	Porcentaje
Árbol de Decisión	20	66.67 %
Red Neuronal Artificial	15	50.00 %
Máquina de Vectores de Soporte	12	40.00 %
Bosque Aleatorio	12	40.00 %
Regresión Ligística	10	33.33 %
K Vecinos más Cercanos	9	30.00 %
Aumento de Gradiente	7	23.33 %
Redes Bayesianas	4	13.33 %
Naive Bayes Gaussiano	2	6.67 %

Tabla 5 – Técnicas de Machine Learning utilizadas en la predicción de deserción académica.

RQ4. ¿Qué métricas se pueden utilizar para evaluar modelos en la predicción de deserción académica?

Las métricas de evaluación permiten contemplar el rendimiento de un modelo de Machine Learning en base a las predicciones que este realiza de tal manera que posibilita la comparación entre diferentes modelos predictivos (Khalid et al., 2022).

La tabla 6, muestra algunas de las diversas métricas usadas para la evaluación de modelos predictivos en la predicción de deserción académica, donde se puede resumir que Precisión (63,33%), Exactitud (60%), Sensibilidad (50%), F1-score (30%) y AUC-ROC (16%) son las métricas que más se repiten en los 30 artículos encontrados.

Métrica	Cantidad	Porcentaje
Precisión	19	63.33 %
Exactitud / Accuracy	18	60.00 %
Sensibilidad / Recall	15	50.00 %
F1-score	9	30.00 %
AUC-ROC	5	16.00 %
Especificidad	2	6.67 %

Tabla 6 – Métricas de evaluación de modelos predictivos en la predicción de deserción académica.

Exactitud (Accuracy): hace referencia a las predicciones clasificadas de manera correcta en relación al total de predicciones realizadas, comúnmente la exactitud es usada junto con otras métricas tales como la precisión y la sensibilidad dado que juntas ofrecen una visión del cómo clasifica los datos el algoritmo predictivo, se calcula tomando en cuenta las predicciones catalogadas como verdaderos positivos, falsos negativos, verdaderos negativos y falsos positivos (Khalid et al., 2022).

$$Exactitud = \frac{VP + VN}{VP + VN + FP + FN}$$

Figura 5 – Fórmula para calcular la exactitud

Precisión: se usa en la evaluación de desempeño de modelos predictivos clasificadores e indica la proporción de predicciones positivas de manera correcta en relación con el total de predicciones positivas (Alhazmi & Sheneamer, 2023).

$$Precisión = \frac{VP}{VP + FP}$$

Figura 6 – Fórmula para calcular la precisión

Sensibilidad: se usa en la evaluación de desempeño de modelos predictivos clasificadores e indica la proporción de predicciones negativas de manera correcta en relación con el total de predicciones negativas (Urbina et al., 2020).

$$Sensibilidad = \frac{VP}{VP + FN}$$

Figura 7 – Fórmula para calcular la sensibilidad

F1-score: hace referencia a la media armónica de la precisión y sensibilidad de un modelo, y además se usa para la evaluación de sistemas de clasificación binaria, su valor varía entre 0 y 1 (Khalid et al., 2022).

$$F1 - score = \frac{2 * precisión * sensibilidad}{precisión + sensibilidad}$$

Figura 8 – Fórmula para calcular F1-score

AUC-ROC: El Área Bajo la Curva de ROC es usado para la evaluación de capacidad de discriminación de un modelo clasificador binario mostrando la asociación entre la

sensibilidad y 1-especificidad dependiendo de diferentes umbrales, su valor varía entre 0 y 1 (Khalid et al., 2022).




Figura 9 – Área Bajo la Curva ROC

5. Conclusiones

La presente revisión sistemática permitió identificar las variables más comunes aplicadas en la predicción de deserción académica, tales como el sexo del estudiante (60%), promedio de calificaciones (53.33%), la edad (43.33%), lugar de procedencia (33.33%), tipo de colegio de procedencia (26.67%), la situación laboral (23.33%) y el estado civil (23.33%).

La presente revisión sistemática permitió identificar algunas de las técnicas de Machine Learning más comunes aplicadas en la predicción de deserción académica tales como los Árboles de Decisión (66.67%), las Redes Neuronales Artificiales (50%), las Máquinas de Vectores de Soporte (40%), los Bosques Aleatorios (40%) y la Regresión Logística (33.33%).

La presente revisión sistemática permitió identificar algunas de las métricas usadas en la evaluación de modelos predictivos más comunes aplicados en la predicción de deserción académica tales como la Precisión (63.33%), Exactitud (60%), Sensibilidad (50%), F1-score (30%) y AUC-ROC (16%).

La presente revisión sistemática permitió recopilar artículos de diferentes bases de datos digitales relacionados al tema de investigación, además se trazaron interrogantes de investigación que permitieron conocer las metodologías, variables, técnicas y métricas de evaluación que se pueden utilizar en la predicción de deserción académica mediante Machine Learning.

Referencias

- Alhazmi, E., & Sheneamer, A. (2023a). Early Predicting of Students Performance in Higher Education. *IEEE Access*, 11, 27579-27589. <https://doi.org/10.1109/ACCESS.2023.3250702>
- Díaz, B., Marín, W., Lioo, F., Baldeos, L., Villanueva, D., & Ausejo, J. (2022). Deserción de estudiantes, factores asociados con árboles de decisión: Caso Escuela de Postgrado 1de una Universidad pública en Perú. *Revista Ibérica de Sistemas e Tecnologias de Informação*, E53, Article E53. <https://www.proquest.com/docview/2768748027/abstract/5AoC18E868F24Co8PQ/21>
- Guzmán Rincón, A., Barragán Moreno, S., Cala-Vitery, F., & Segovia-García, N. (2022). Deserción en la Educación Superior Rural: Análisis de Causas desde el Pensamiento Sistémico. (Spanish): Dropout in Rural Higher Education: Analysis of Causes from Systemic Thinking. (English). *Qualitative Research in Education* (2014-6418), 11(2), 118-150. <https://doi.org/10.17583/qre.10048>
- Khalid, O., Sarah, A., & Khalifa, M. (2022). Towards a Students' Dropout Prediction Model in Higher Education Institutions Using Machine Learning Algorithms. *International Journal of Emerging Technologies in Learning*, 17(18), Article 18. <https://doi.org/10.3991/ijet.v17i18.25567>
- Kwasi Dake, D., & Buabeng Andoh, C. (2022). Using Machine Learning Techniques to Predict Learner Drop-out Rate in Higher Educational Institutions. *Mobile Information Systems*, 1-9. <https://doi.org/10.1155/2022/2670562>
- Medina, E. C., Armas-Aguirre, J., Chunga, C. B., & Grandón, E. E. (2020). Modelo predictivo para reducir el índice de deserción de estudiantes universitarios en el Perú: Redes Bayesianas vs. Árboles de Decisión: Predictive model to reduce the dropout rate of university students in Perú: Bayesian Networks vs. Decision Trees. *CISTI (Iberian Conference on Information Systems & Technologies / Conferência Ibérica de Sistemas e Tecnologias de Informação) Proceedings*, 1-7. <https://search.ebscohost.com/login.aspx?direct=true&db=iuh&AN=147256181&lang=es&site=eds-live>
- Nabil, A., Seyam, M., & Abou-Elfetouh, A. (2021). Prediction of Students' Academic Performance Based on Courses' Grades Using Deep Neural Networks. *IEEE Access*, 9, 140731-140746. <https://doi.org/10.1109/ACCESS.2021.3119596>
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., Shamseer, L., Tetzlaff, J. M., Akl, E. A., Brennan, S. E., Chou, R., Glanville, J., Grimshaw, J. M., Hróbjartsson, A., Lalu, M. M., Li, T., Loder, E. W., Mayo-Wilson, E., McDonald, S., ... Moher, D. (2021). Declaración PRISMA 2020: Una guía actualizada para la publicación de revisiones sistemáticas. *Revista Española de Cardiología*, 74(9), 790-799. <https://doi.org/10.1016/j.recesp.2021.06.016>
- Segura, M., Mello, J., & Hernández, A. (2022). Machine Learning Prediction of University Student Dropout: Does Preference Play a Key Role? *Mathematics*, 10(18), Article 18. <https://doi.org/10.3390/math10183359>

- Urbina, A., Camino, J., & Cruz, R. (2020). Deserción escolar universitaria: Patrones para prevenirla aplicando minería de datos educativa. *Revista Electrónica de Investigación y Evaluación Educativa*, 26(1), Article 1. <https://doi.org/10.7203/relieve.26.1.16061>
- Valero, J., Navarro, Á., Larios, A., & Julca, J. (2022). Deserción universitaria: Evaluación de diferentes algoritmos de Machine Learning para su predicción. *Revista de Ciencias Sociales*, 28(3), Article 3. Scopus. <https://doi.org/10.31876/rcs.v28i3.38480>
- Vega, H., Sanz, E., De La Cruz, P., Moquillaza, S., & Pretell, J. (2022). Intelligent System to Predict University Students Dropout. *International Journal of Online & Biomedical Engineering*, 18(7), 27-43. <https://doi.org/10.3991/ijoe.v18i07.30195>

© 2023. This work is published under
<https://creativecommons.org/licenses/by-nc-nd/4.0/>(the
“License”). Notwithstanding the ProQuest Terms and
Conditions, you may use this content in accordance with the
terms of the License.